

Universitatea Națională de Știință și Tehnologie
POLITEHNICA București
Facultatea de Electronică, Telecomunicații și Tehnologia Informației

*Analiza imaginilor cu fund de ochi pentru ajutor în
diagnosticul retinopatiei diabetice*

Proiect de diplomă

prezentat ca cerință parțială pentru obținerea titlului de
Inginer în domeniul Calculatoare și Tehnologia Informației
program de studii de licență Ingineria Informației

Conducător științific,
Conf. Dr. Ing. Laura-Maria Florea

Absolvent,
Ștefan BOSIE

Anul 2026

TEMA PROIECTULUI DE DIPLOMĂ

a studentului **BOSIE C. Ștefan, 442A**

1. Titlul temei: Analiza imaginilor cu fund de ochi pentru ajutor în diagnosticul retinopatiei diabetice

2. Descrierea temei:

Retinopatia diabetică este o boală oculară cronică progresivă asociată unui grup de probleme oculare ca o complicație a diabetului. Această boală poate provoca pierdere severă a vederii sau chiar orbire. Specialiștii analizează imagini de fund de ochi pentru a diagnostica boala și a oferi tratamente specifice. Clasificarea corectă a imaginilor cu fund de ochi depinde de abilitatea și experiența specialiștilor, precum și de calitatea imaginilor. Scopul lucrării de față este de a folosi algoritmi de vedere computerizată bazați pe rețele convoluționale adânci pentru a crea o metodă de detectare a retinopatiei diabetice. Metoda se va testa pe seturi de date publice. Implementarea se va face în Python folosind biblioteci specifice.

3. Contribuția originală:

1. Se vor cauta seturi de date publice ce contin imagini cu fund de ochi si adnotari pentru detectia retinopatiei diabetice. 2. Se vor analiza seturile de date gasite. 3. Se va antrena o retea convolutionala adanca pentru detectia retinopatiei diabetice. 4. Se va analiza performanta retelei in diverse cazuri de antrenare/testare.

4. Resurse și bibliografie:

Alyoubi, W. L., Shalash, W. M., Abulkhair, M. F. (2020). Diabetic retinopathy detection through deep learning techniques: A review. Informatics in Medicine Unlocked, 20, 100377.

5. Data înregistrării temei: 2026-01-16 13:53:06

Conducător(i) lucrare,

Conf. dr. ing. Laura Maria FLOREA

Student,

BOSIE C. Ștefan

Director department,

Ș.L. dr. ing Bogdan FLOREA

Decan,

Prof. dr. ing. Mihnea Udrea

Cod Validare: **f92c3f1870**

Declarație de onestitate academică

Prin prezenta declar că lucrarea cu titlul „*Analiza imaginilor cu fund de ochi pentru ajutor în diagnosticul retinopatiei diabetice*”, prezentată în cadrul Facultății de Electronică, Telecomunicații și Tehnologia Informației a Universității Naționale de Știință și Tehnologie POLITEHNICA București ca cerință parțială pentru obținerea titlului de Inginer/ Master în domeniul *Calculatoare și Tehnologia Informației*, programul de studii *Ingineria Informației* este scrisă de mine și nu a mai fost prezentată niciodată la o facultate sau instituție de învățământ superior din țară sau străinătate.

Declar că toate sursele utilizate, inclusiv cele de pe Internet, sunt indicate în lucrare, ca referințe bibliografice. Fragmentele de text din alte surse, reproduse exact, chiar și în traducere proprie din altă limbă, sunt scrise între ghilimele și fac referință la sursă. Reformularea în cuvinte proprii a textelor scrise de către alți autori face referință la sursă. Înțeleg că plagiatul constituie infracțiune și se sancționează conform legilor în vigoare.

Declar că toate rezultatele simulărilor, experimentelor și măsurărilor pe care le prezint ca fiind făcute de mine, precum și metodele prin care au fost obținute, sunt reale și provin din respectivele simulări, experimente și măsurători. Înțeleg că falsificarea datelor și rezultatelor constituie fraudă și se sancționează conform regulamentelor în vigoare.

București, 20.VI.2026

Absolvent Ștefan BOSIE



Cuprins

Introducere	17
Capitolul 1: Fundamente teoretice ale retinopatiei diabetice	19
Capitolul 2: Metode existente în literatura de specialitate	23
2.1 Metode tradiționale	23
2.2 Metode bazate pe algoritmi de inteligență artificială.....	23
2.2.1. Metode bazate pe învățare supervizată	23
2.2.2 Metode bazate pe învățare auto-supervizată	24
2.2.3. Arhitecturi de tip Transformer.....	25
Capitolul 3: Metoda propusă.....	27
3.1. Schema bloc	27
3.2. Etapele de pre-procesare și restaurare a imaginilor	28
3.2.1 Algoritmul de pre-procesare CLAHE	28
3.2.2 Algoritmul de pre-procesare Ben Graham	29
3.2.3 Algoritmul de pre-procesare Shades-of-Gray + CLAHE.....	30
3.3 Augmentări Utilizate	31
3.4. Modele Utilizate.....	36
3.4.1. Modelul Residual Networks(ResNet)	37
3.4.2. Modelul EfficientNet	41
3.5. Metode de Antrenare și Optimizare a Modelului.....	45
3.5.1. Învățare prin transfer și Strategia de Adaptare Fină.....	45
3.5.2. Dinamica Hiperparametrilor: Dimensiunea Lotului și Epocile de Învățare	45
3.5.3. Strategii de Regularizare	46
3.5.4. Funcții de Cost și adaptarea dezechilibrelor la nivelul claselor.....	47
3.5.5. Algoritmul de optimizare și planificarea ratei de învățare	48
3.5.6. Clasificarea Multiclasă și Regresia Ordinală	50
3.6. Metode de evaluare a modelului	51
3.7. Explicabilitatea deciziilor folosind algoritmul Grad-CAM	54
Capitolul 4: Rezultate Experimentale	57
4.1 Setul de date utilizat.....	57
4.2. Rezultate Experimentale	61

4.2.1. Experimente bazate pe arhitectura ResNet50	61
4.2.2. Experimente bazate pe arhitectura EfficientNet-B3	79
Concluzii și direcții viitoare de cercetare.....	93
Bibliografie	95
Anexă Cod.....	99

Lista figurilor

1.1. Fotografie fundoscopică a unei retine sănătoase. Sursa [2]	19
1.2. Retină afectată de retinopatie diabetică neproliferativă ușoară. Sursa [3]	20
1.3. Retină afectată de retinopatie diabetică neproliferativă moderată. Sursa [3]	20
1.4. Retină afectată de retinopatie diabetică neproliferativă severă. Sursa [3]	21
1.5. Retină afectată de retinopatie diabetică proliferativă. Sursa [3]	21
3.1. Schema bloc aferentă etapei de antrenare. Diagramă generată cu ajutorul sursei [7]	27
3.2. Schema bloc aferentă etapelor de validare/testare. Diagramă generată cu ajutorul sursei [7]	27
3.3. Imagine supraexpusă la lumină.....	28
3.4. Imagine subexpusă la lumină.	28
3.5. Succesiunea de pre-procesări aplicate asupra imaginilor brute	29
3.6. Demonstrație vizuală pre-procesare Ben Graham.	30
3.7. Succesiunea de pre-procesări Shades-of-Gray + CLAHE aplicate asupra unei imagini de tip fund de ochi.....	31
3.8. Aplicare transformată de tip oglindire orizontală asupra imaginii.....	32
3.9. Aplicare transformare de rotație cu un unghi de 45° asupra imaginii originale.....	32
3.10. Aplicare transformare de scalare cu o rată supraunitară de 1.3 asupra imaginii originale.....	33
3.11. Aplicare transformată de iluminare, cu un factor de perturbare egal cu 60	33
3.12. Aplicare transformată de contrast, cu un factor de scalare $c=1.8$, intensitatea medie egală cu 128	34
3.13. Aplicare zgomot gaussian independent de dispersie 30	35
3.14. Eliminare în mod aleator a porțiunilor din imagine	35
3.15. Tipuri de augmentări aplicate asupra unei imagini pre-procesate Ben Graham din cadru setului de test.....	36
3.16. Reprezentarea unei conexiuni reziduale. Sursa [16]	37
3.17. Structură de tip Basic Bloc. Sursa [18]	38
3.18. Componenta blocurilor de tip Residual Building Block. Sursa [19]	39
3.19. Arhitectura standard ResNet50. Sursa [20]	40

3.20. Realizarea scalărilor după cele 3 dimensiuni prezentate (lățime, adâncime, rezoluție). Sursa [21].	41
3.21. Arhitectura rețelei EfficientNet-B0. Sursa [21]	42
3.22. Arhitectura rețelei EfficientNet-B3. Sursa [22]	44
3.23. Variația ratei de învățare pentru $T_{total}=160k$ epoci, $T_{peak}=40k$ epoci, iar $\eta_{max}=0.1$. Sursa [34]	50
3.24. Matrice de confuzie	52
3.25. Validarea deciziei modelului folosind Grad-CAM	55
4.1. Fotografie specifică clasei 0_No_Diabetic_Retinopathy. Sursa [3]	58
4.2. Fotografie specifică clasei 1_Mild. Sursa [3]	58
4.3. Fotografie specifică clasei 2_Moderate. Sursa [3]	59
4.4. Fotografie specifică clasei 3_Severe. Sursa [3]	59
4.5. Fotografie specifică clasei 4_Proliferative. Sursa [3]	60
4.6. Histograma distribuției imaginilor	60
4.7. Histograma datelor de antrenare, în urma subeșantionării lotului de antrenare	61
4.8. Arhitectura utilizată	62
4.9. Evoluția metricii de acuratețe pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul primului experiment	63
4.10. Evoluția funcției de pierderi pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul primului experiment	64
4.11. Histograma datelor de antrenare, în urma adăugării de noi eșantioane în lot	65
4.12. Evoluția metricii de acuratețe pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul celui de-al doilea experiment	65
4.13. Evoluția metricii de eroare pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul celui de-al doilea experiment	66
4.14. Evoluția metricii de acuratețe după 15 epoci, în urma efectuării pre-procesărilor asupra lotului de date	67
4.15. Evoluția metricii de acuratețe după 18 epoci, în urma efectuării pre-procesării Ben Graham	69
4.16. Evoluția metricii de acuratețe, în urma aplicării augmentărilor geometrice	70
4.17. Evoluția funcției de eroare, în urma aplicării augmentărilor geometrice	71
4.18. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning	72

4.19. Evoluția metricii de eroare, pe parcursul celor 5 etape de Fine Tuning.....	73
4.20. Matricea de confuzie pentru modelul obținut în urma procesului de Fine Tuning	74
4.21. Implementarea arhitecturii cascade	75
4.22. Evoluția acurateții primului model de clasificare binară, pentru 5 etape succesive de Fine-Tuning	76
4.23. Evoluția metricilor de măsură pentru fiecare prag ales, pentru cazul în care fiecare clasă are pondere egală.....	77
4.24. Evoluția metricilor de măsură pentru fiecare prag ales, pentru cazul în care fiecare rezultatul fiecărei măsurători este proporțională cu numărul de poze din fiecare clasă ..	77
4.25. QWK în funcție de fiecare prag selectat	78
4.26. Matricea de confuzie pentru modelul cascade, prag de 0.5	79
4.27. Arhitectura pentru EfficientNet-B3	80
4.28. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning.....	81
4.29. Evoluția metricii de eroare pe parcursul celor 5 etape de Fine-Tuning	81
4.30. Matricea de confuzie pentru modelul obținut, utilizând arhitectura EfficientNet-B3 și pre-procesarea Ben Graham	82
4.31. Noul pipeline de clasificare.....	83
4.32. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning.....	84
4.33. Evoluția metricii de eroare pe parcursul celor 5 etape de Fine-Tuning	84
4.34. Matricea de confuzie pentru modelul obținut, utilizând arhitectura EfficientNet-B3 și pre-procesarea CLAHE	85
4.35. Evoluția metricii de acuratețe în cazul regresiei ordinale	86
4.36. Evoluția funcției de eroare	87
4.37. Matricea de confuzie în cazul regresiei ordinale	87
4.38. Matricea de confuzie pentru regresie ordinală, parametrul $\gamma=0.75$	89
4.39. Evoluția metricii de acuratețe, pentru pre-procesarea Shades-of-Gray	90
4.40. Matricea de confuzie pentru setul de test pre-procesat Shades-of-Gray.....	90

Lista tabelelor

3.1. Matricea de confuzie aferentă unei clase	51
4.1. Valoarea metricilor de măsură pentru experimentul 6	74
4.2. Precizie, Reamintire și Scor F1 pentru fiecare din cele 5 clase, pentru pragul de 0.5	79
4.3. Valoarea măsurătorilor de acuratețe, precizie, reamintire, scor F1 și QWK pentru experimentul 8.....	82
4.4. Valoarea metricilor de interes pentru experimentul 9	85
4.5. Valori ale metricilor de precizie, reamintire, scor F1, acuratețe globală, QWK, pentru experimentul 10	88
4.6 Metrici de evaluare a modelului obținut în experimentul 11	91

Lista acronimelor

IDRiD = Indian Diabetic Retinopathy Image Dataset
CNN = Convolutional Neural Network
ResNet = Residual Network
Xception = Extreme Inception
ViT = Visual Transformer
MLP = Multi-Layer Perceptron
CAB = Category Attention Block
GAB = Global Attention Block
CABNet = Category Attention Block Net
SVM = Support Vector Machine
CLAHE = Contrast Limited Adaptive Histogram Equalization
RGB = Red Green Blue
LAB = Luminance, A axis, B axis
ReLU = Rectified Linear Unit
RBB = Residual Building Block
FLOPS = Floating Point Operations Per Second
MBConv = Mobile Inverted Bottleneck Convolution
SE = Squeeze-and-Excitation
TP = True Positive
FP = Fals Positive
FN = Fals Negative
TN = True Negative
QWK = Quadratic Weighted Kappa
APTOS = Asia-Pacific Tele-Oftalmologie Society
DR = Diabetic Retinopathy
Adam = Adaptive Moment Estimation
GAN = Generative Adversarial Networks
Grad-CAM = Gradient-weighted Class Activation Mapping

Introducere

Diabetul zaharat constituie o problemă majoră de sănătate publică la nivel global, înregistrând o incidență în continuă și rapidă creștere. Această afecțiune declanșează numeroase complicații de ordin vascular la nivelul întregului organism, iar printre cele mai severe se numără retinopatia diabetică, aceasta reprezentând principala cauză a pierderii vederii în rândul populației diagnosticate cu diabet.

Scopul lucrării de diplomă constă în dezvoltarea unei aplicații software bazată pe utilizarea rețelelor neuronale convoluționale adânci, capabilă de a detecta și clasifica stadiile de evoluție ale retinopatiei diabetice, pe baza imaginilor brute cu fund de ochi. Arhitectura realizată va extrage caracteristici specifice precum forma și geometria vascularizațiilor nervoase, modificări înregistrate ale maculei, prezența microanevrismelor. Pe baza acestor indicatori, sistemul va clasifica pacienții într-una din cele 5 clase distincte ce indică gradele de severitate ale afecțiunii: absența afecțiunii, cele trei etape ale retinopatiei diabetice neproliferative (ușoară, moderată, severă) și faza terminală, reprezentată de retinopatia proliferativă.

Motivația efectuării acestei lucrări se bazează în primul rând pe dorința de a inova infrastructura de diagnostic medical. Un algoritm capabil să detecteze și să clasifice automat prezența retinopatiei diabetice poate fi livrat și utilizat pe scară largă de către medicii oftalmologi drept instrument de sprijin. Automatizând procesul de detecție, volumul de muncă al specialiștilor va fi redus semnificativ. Un astfel de program poate fi utilizat pe scară largă în rândul comunităților defavorizate, unde accesul la medici specialiști este limitat.

Din perspectivă academică, abordarea unui proiect de diplomă centrat pe metode de învățare profundă va oferi prilejul de a aplica noțiuni teoretice despre imagistică digitală și inteligență artificială acumulate în anii de dezvoltare academică din cadrul studiilor de licență pentru a rezolva o problemă de natură clinică. Elaborarea lucrării a facilitat asimilarea unor noi metode de pre-procesare și restaurare a imaginilor, tehnici de eliminare a zgomotului, cât și de evidențiere a detaliilor ce înglobează informație utilă. Totodată, efectuarea lucrării impune realizarea unui studiu aprofundat asupra modalităților de antrenare și optimizare a celor mai populare arhitecturi de rețele neuronale, modalități de combatere a dezechilibrelor de date, cât și diverse metode de evaluare statistică a capacității de generalizare a modelelor.

Pentru a soluționa problema clasificării, se vor studia abordările utilizate pentru problemele de imagistică medicală. Metoda implementată în lucrare se va baza pe tehnica transferului de cunoștințe, utilizând rețele convoluționale pre-antrenate pe setul de date ImageNet, care vor fi ulterior adaptate pentru specificul structurilor retiniene. Pe baza literaturii de specialitate, se vor adapta metodele existente pentru a genera un pipeline de procesare riguros, selectând soluția optimă obținută pe baza metricilor de performanță specifice domeniului medical.

Lucrarea a fost structurată în patru capitole fundamentale, după cum urmează:

- Primul capitol analizează aspectele fundamentale ale bolii, detaliind simptomele specifice, modificările de la nivelul retinei și metodele medicale utilizate în prezent pentru tratamentul pacienților.
- Al doilea capitol include un studiu al literaturii de specialitate în care se vor analiza diverse abordări ale cercetătorilor din domeniu, evidențiindu-se atât avantajele, cât și limitările soluțiilor existente.
- Al treilea capitol descrie fundamentul teoretic al soluției implementate. Vor fi prezentate tehnicile de pre-procesare și augmentare a imaginilor, structura rețelelor neuronale alese, funcțiile de cost și metodele pentru optimizarea modelului, cât și metricile de evaluare a modelului.
- Al patrulea capitol este dedicat centralizării tuturor experimentelor efectuate pentru setul de date achiziționat. Performanțele diferitelor configurații sunt analizate riguros prin intermediul matricelor de confuzie și al măsurătorilor statistice, evidențiindu-se avantajele, dezavantajele și capacitatea finală de generalizare a modelelor obținute.

Capitolul 1: Fundamente teoretice ale retinopatiei diabetice

Retinopia Diabetică este clasificată de către medicii diabetologi drept o complicație a diabetului zaharat de tip I și II. Afectează o treime din persoanele diagnosticate cu diabet, regăsindu-se cu precădere în rândul persoanelor de vârstă mijlocie, cât și în rândul vârstnicilor [1].

Retinopia diabetică se instalează în urma expunerii îndelungate la hiperglicemie cronică. Vasele de sânge de la nivelul retinei vor fi deteriorate treptat, iar în timp vor provoca dificultăți majore ale vederii [2].

Pentru a depista retinopia diabetică, medicii oftalmologi utilizează un dispozitiv dedicat pentru a capta imaginea retinei la nivelul globului ocular, cunoscut drept cameră fundoscopică.

Aspectele cheie ale retinei ce trebuie monitorizate în cadrul unei fotografii fundoscopice sunt discul optic și macula. Figura 1.1 ilustrează aspectul fundului de ochi unui ochi drept. Discul optic poate fi identificat urmărind vasele de sânge până la punctul acestora de confluență. În fotografie acesta se situează în partea dreaptă, are o formă circulară și este de culoare galbenă. Macula se află în partea stângă, suprafața acesteia fiind mai puțin vascularizată. Partea centrală a maculei este foveea. Aceasta are diametrul comparabil cu discul optic, iar culoarea sa mai închisă este cauzată de prezența unui pigment suplimentar. Foveea este zona cea mai bogată în celule conice [2].




Figura 1.1. Fotografie fundoscopică a unei retine sănătoase. Sursa [2]

Retinopia diabetică se poate dezvolta în 4 stadii diferite, în funcție de severitatea cu care globul ocular este afectat. Primul stadiu patologic ce poate fi identificat în cadrul unei examinări este retinopia diabetică neproliferativă, ce se poate clasifica în 3 etape distincte: ușoară, moderată sau severă.



Figura 1.2. Retină afectată de retinopatie diabetică neproliferativă ușoară. Sursa [3]

Figura 1.2 ilustrează aspectul unei retine afectate de retinopatie diabetică neproliferativă ușoară. Se observă prezența unor microanevrisme, acestea fiind vizibile sub forma unor leziuni punctiforme de culoare galben-roșiatică ce permit scurgeri de sânge. Capilarele retiniene sunt ușor dilatate, observându-se totodată și o vascularizare mai puternică comparativ cu figura 1.1. În această etapă, vederea nu este afectată, majoritatea pacienților neexperimentând simptome .




Figura 1.3. Retină afectată de retinopatie diabetică neproliferativă moderată. Sursa [3]

În cazul etapei moderate a retinopatiei diabetice, în figura 1.3 se accentuează faptul că fluxul sanguin către retină se va efectua din ce în ce mai greu, principala cauză fiind dilatarea mai pronunțată a vaselor de sânge. Vor fi vizibile simptome în rândul pacienților, odată cu acumularea unui nivel mai ridicat de sânge la nivelul maculei, vederea va deveni din ce în ce mai încețoșată [1]. În zona maculei, capilarele sunt mai dilatate, provocând scurgeri ce pot afecta vederea. Se observă prezența microanevrismelor care de această dată sunt mai numeroase, de dimensiuni mai mari față de cazul precedent.




Figura 1.4. Retină afectată de retinopatie diabetică neproliferativă severă. Sursa [3]

În etapa severă a afecțiunii, vasele de sânge vor deveni puternic neregulate și dilatate. Acest lucru este cauzat de diminuarea nivelului de oxigen din interiorul retinei, ca urmare a fluxului sanguin redus [1]. În figura 1.4 se remarcă o vascularizare anormală a capilarelor. Microanevrismele sunt din ce în ce mai mari și mai numeroase, ca rezultat al scurgerii unei cantități mai mari de sânge prin pereții vaselor. În această etapă vederea poate fi pierdută permanent, în funcție de cantitatea de fluid care se scurge prin maculă [1].




Figura 1.5. Retină afectată de retinopatie diabetică proliferativă. Sursa [3]

Ultimul stadiu al afecțiunii este reprezentat de retinopatia de tip proliferativ. O fotografie fundoscopică specifică acestui stadiu poate fi vizualizată în figura 1.5. Retina nu mai are acces la oxigen. Vasele de sânge se vor dezvolta anormal, ajungând până la corpul vitros (situat în partea posterioară a ochiului) [1]. Suprafața retinei este de culoare roșu-închis, din cauza sângerării excesive care are loc prin pereții capilarelor. Pe suprafața nervului optic este vizibilă o puternică vascularizare.

În concluzie, retinopatia diabetică este o problemă de sănătate tot mai întâlnită în rândul persoanelor diagnosticate cu diabet zaharat [1]. Cu toate acestea, evoluția infrastructurii din domeniul medical, cât și apariția medicamentelor specifice reușesc să trateze această afecțiune, stopând evoluția până în etapele avansate, în care simțul vizual poate fi puternic degradat.

Capitolul 2: Metode existente în literatura de specialitate

Pentru a identifica ce abordare este cea mai potrivită în cadrul aplicației de clasificare a retinopatiei diabetice, am descoperit o serie de soluții studiind diverse articole de specialitate. De-a lungul timpului, se observă faptul că au fost abordate diverse metode, pentru a fi în conformitate cu noile tehnologii utilizate pentru perioada respectivă.

2.1 Metode tradiționale

O primă abordare adoptată în anul 1966 se bazează pe evaluarea leziunilor individuale [4], la nivelul fiecărei poze înregistrate de aparatele fundoscopice. Pentru fiecare poză, se identificau detalii specifice precum modificări venoase, microanevrisme și hemoragii, exsudate, despre care s-a constatat faptul că acestea puteau varia independent una față de celelalte. În urma analizării fiecărei leziuni, se dădea un verdict final asupra tipului de retinopatie dominant la nivelul globului ocular [4]. Un principal dezavantaj al acestei metode consta în faptul că realizarea desenelor detaliate pentru a identifica leziunile la nivelul retinei prin oftalmoscopie necesită un timp îndelungat de lucru, fiecare procedură realizându-se manual de către medicul oftalmolog.

O altă abordare ce datează din 1967 are la bază sistemul de gradare Hammersmith [4], introducând în premieră conceptul de fotografie fundoscopică, reușind astfel să înlocuiască oftalmoscopia. Leziunile specifice retinopatiei au fost redată cu ajutorul a 4 fotografii standard în același cadru, fiind mult mai accesibil de evaluat de către medici [4]. Cu toate acestea, această abordare a fost limitată de infrastructura aparatelor de fotografiat, care în unele cazuri nu reușeau să înregistreze complet totalitatea microanevrismelor la nivelul pacienților. Similar cazului precedent, fiecare clasificare era realizată manual de către medicul oftalmolog, acest proces derulându-se pe o durată îndelungată de timp.

2.2 Metode bazate pe algoritmi de inteligență artificială

Cele mai noi metode utilizate preponderent în ultimul deceniu au la bază clasificarea retinopatiei diabetice pe baza tehnicilor de inteligență artificială și învățare profundă. Acestea și-au dovedit performanța în diverse aplicații de natură medicală [4], în special în cazul problemelor de clasificare.

În cazul detecției retinopatiei diabetice, algoritmi generici de Machine Learning precum RandomForest și SVM(Support Vector Machine) au înregistrat rezultate sub așteptări [4], fiind necesară utilizarea modelelor de învățare profundă pentru a rezolva problema clasificării.

2.2.1. Metode bazate pe învățare supervizată

O primă abordare se bazează exclusiv asupra modelelor supervizate. Se va aborda clasificarea de tip multiclasă, în care fiecare pacient este clasificat în funcție de gradul de severitate pe care pacientul îl prezintă (vor exista 5 etichete, sănătos, ușor, moderat, sever, proliferativ) [4]. Această

abordare are la bază utilizarea modelelor de tip CNN (Convolutional Neural Network) [5] ce au la bază operația de convoluție. Convoluția este operația matematică ce presupune glisarea unei ferestre peste o matrice de valori inițiale, iar ulterior se efectuează suma ponderată a pixelilor aflați la intrare.

Într-o primă etapă, imaginile au fost pre-procesate pentru a spori calitatea acestora și pentru a extrage maximul de informație posibil. S-au utilizat operații de decupare, redimensionare, egalizare adaptivă de histogramă [4]. Pentru a preveni situația în care modelul este predispus supraînvățării datelor de intrare, s-au adăugat o serie de augmentări datelor de antrenare precum rotații, aplicare de zgomot Gaussian, scalări, oglindiri cât și decupări ale anumitor zone din imagine.

În ceea ce privește modelul utilizat, atât Abramoff et al. [4] cât și Tymchenko et al. [4] folosesc modele pre-antrenate pe diverse seturi de date, precum ResNet50, InceptionV3, Xception(Extreme Inception), ce au fost ajustate fin pentru a rezolva problema de natură medicală. Abramoff a adăugat la ieșirea rețelei straturi complet conectate suplimentar.

O altă arhitectură propusă de către Li et al. [4] utilizează rețeaua ResNet50 pentru a extrage caracteristici utilizând setul de date IDRiD(Indian Diabetic Retinopathy Image Dataset), iar mai apoi 4 module de atenție sunt atașate la ieșire. Primele 2 module de atenție conțin straturi de reducere prin mediere, reducere prin maxim, concatenare, ultimele 2 conținând exclusiv straturi complet conectate [4].

Tymchenko et al. [4] utilizează o rețea convoluțională adâncă preantrenată pe setul de date ImageNet. Pentru etapa de antrenare, aceștia au combinat mai multe seturi de date, precum Kaggle EyePacs, IDRiD care conține 413 imagini și setul Messidor ce are în componența sa 1200 de imagini fundoscopice. Abordarea sa se bazează pe utilizarea a 3 capete decizionale, fiecare specializat pentru a rezolva sarcini diferite (primul cap abordează problema clasificării, al doilea transformă problema într-o problemă de regresie, rezultatul final indicând în ce stadiu se situează pacientul, iar cel de-al treilea cap de clasificare descompune problema într-una de clasificare progresivă, în care etichetele vor fi continue și cumulate). Ansamblul celor 3 capete de decizie va reprezenta răspunsul oferit de model.

2.2.2 Metode bazate pe învățare auto-supervizată

Metodele de învățare supervizată pot fi vulnerabile în situațiile în care datele sunt zgomotoase, sau pot exista neconcordanțe în ceea ce privește adnotarea imaginilor (această situație este frecvent întâlnită, în special pentru problemele medicale), fiind introduse astfel metodele de învățare auto-supervizate. Această metodă reușește să identifice trăsături discriminative fără să se bazeze pe adnotări [6]. He et al. [4] introduc Blocul de Atenție pe Categorie (CAB), menit să se concentreze exclusiv asupra trăsăturilor bazate pe regiuni pentru fiecare etapă a retinopatiei diabetice [6]. Modulul CAB poate fi integrat în diverse blocuri ce nu sunt centrate pe categorie, pentru a îmbunătăți procesul de clasificare.

Woo et al. [4] propun o rețea personalizată de gradare a retinopatiei, cunoscută drept CABNet [4]. În componența acesteia, se poate utiliza orice arhitectură de tip CNN, căreia îi va fi atașată la ieșire un strat de convoluție de nucleu 1x1 strict pentru a reduce numărul canalelor. Rezultatul este trimis către Blocul de Atenție Globală (GAB) care are rolul de a extrage contextul global al imaginii, ignorând textura și culoarea. Mai departe, Blocul de Atenție pe Categorie (CAB) se concentrează

asupra leziunilor și a detaliilor minore. Ca și în cazul clasificărilor de tip supervizat, modelul CNN a fost preantrenat pe setul de date ImageNet [4].

Un dezavantaj major al modelelor auto-supervizate, este faptul că această metodă consumă foarte multe resurse computaționale, în același timp este nevoie ca aceste modele să fie susținute de cantități semnificativ mai mari de date comparativ cu modelele specifice învățării supervizate. Aceste rețele sunt mult mai predispuse să supraînvețe atunci când datele sunt limitate [6].

2.2.3. Arhitecturi de tip Transformer

O altă abordare este utilizarea unui Visual Transformer [4], acest mecanism readaptând mecanismul de atenție pentru date de tip text pentru a fi aplicate în imagini. Imaginile vor fi împărțite în patch-uri de câte 16 x 16 pixeli, sub forma unor reprezentări vectoriale. Acestea vor constitui elementele de intrare în encoderul Transformerului. În interiorul arhitecturii, vectorii de intrare vor trece printr-un multi-cap de atenție, rezultatul va fi normalizat și trimis către stratul MLP(Multi-Layer Perceptron) pentru etapa de clasificare. Însă ca principal dezavantaj, ca și în cazul mecanismelor de atenție din capitolul precedent, acestea trebuie să primească la intrare cantități masive de date, pentru a evita fenomenul de supraînvățare [4]

Capitolul 3: Metoda propusă

Pe baza resurselor computaționale și a setului de date de care dispun, s-a optat pentru abordarea unei metode de tip învățare supervizată. Voi utiliza o rețea convoluțională preantrenată, pentru care voi utiliza procedeul de Transfer Learning pentru a adapta ponderile să detecteze cele 5 etape ale retinopatiei diabetice.

3.1. Schema bloc

Într-o primă etapă voi pre-procesa întreg setul de date, urmând să augmentez datele de antrenare utilizând transformări afine precum rotiri, oglindiri și transpuneri. Aceste transformări sunt absolut vitale pentru ca rețeaua să poată generaliza întreg lotul de testare. Voi antrena mai multe arhitecturi de rețele convoluționale sub diverse configurații, urmând ca la ieșirea rețelei să adaug elemente de regularizare precum straturi de Dropout și straturi de reducere prin mediere. Voi testa și modele ce au mecanisme de atenție integrate, precum EfficientNet. Într-un final, voi analiza fiecare model obținut pentru a-l selecta pe cel ce cu rezultatele cele mai optime.

În figura 3.1, este concretizată schema bloc specifică metodei propuse pentru etapa de antrenare a modelului.



Figura 3.1. Schema bloc aferentă etapei de antrenare. Diagramă generată cu ajutorul sursei [7]

Pentru etapa de testare am eliminat etapa de augmentare specifică exclusiv antrenării. Conform figurii 3.2, imaginile vor fi pre-procesate, iar mai apoi modelul ce a fost antrenat în etapa precedentă va fi evaluat pentru a stabili rezultatele pe care acesta le oferă.



Figura 3.2. Schema bloc aferentă etapelor de validare/testare. Diagramă generată cu ajutorul sursei [7]

Implementarea soluției propuse a fost realizată în limbajul Python 3, utilizând framework-ul TensorFlow/Keras pentru construirea și antrenarea modelelor neuronale. Pre-procesarea imaginilor a fost efectuată cu ajutorul bibliotecii OpenCV, iar augmentările dinamice au fost aplicate prin intermediul bibliotecii Albumentations. Evaluarea modelelor s-a bazat pe metricile oferite de biblioteca Scikit-learn. Antrenarea s-a desfășurat pe platforma Kaggle, utilizând două unități GPU NVIDIA Tesla T4 (13.7 GB VRAM fiecare).

3.2. Etapele de pre-procesare și restaurare a imaginilor

Etapa de pre-procesare a imaginilor este esențială pentru obținerea unor imagini în care detaliile sugestive precum microanevrisme, leziuni, vascularizări să poată fi vizibile și detectabile de către model. Pozele au fost extrase de la diverse clinici și realizate sub diverse unghiuri și iluminări necorespunzătoare. Figurile 3.3, respectiv 3.4 redau poze în care imaginile au fost supraexpuse, fie subexpuse.



Figura 3.3. Imagine supraexpusă la lumină




Figura 3.4. Imagine subexpusă la lumină

Ca primă etapă de pre-procesare, s-a aplicat o metodă de decupare a zonei de interes. Imaginea a fost convertită în tonuri de gri, aplicându-se ulterior o segmentare bazată pe un prag binar cu valoarea 10. Astfel, pixelii ce au o valoare deasupra pragului vor deveni complet albi, restul rămânând la nivelul negru, pentru a separa fundul optic de fundal. Mai apoi, se va calcula și selecta cel mai mare contur, pentru a centra globul ocular și a elimina marginile negre inutile.

În pasul următor, imaginea a fost redimensionată la 512×512 pixeli, după care s-a generat o matrice cu valori nule, iar în centru a fost inițializat un cerc corespunzând formei globului ocular, pentru care s-au generat valori de 255 (corespunzător culorii alb). Aplicând operația bitwise_and între pixelii imaginii redimensionate și matricea generată, se vor păstra doar valorile pixelilor ce corespund structurii ochiului, iar fundalul va fi inițializat cu valoarea 0. Arhitectura se va concentra exclusiv asupra zonei anatomice, și va ignora complet zonele de fundal.

3.2.1 Algoritmul de pre-procesare CLAHE

În continuare se remarcă situația în care unele imagini sunt fie sub-expuse, fie supraexpuse. În alte situații, anumite zone ale imaginii sunt expuse vizibil, existând totuși doar anumite zone ce nu sunt suficient de vizibile, pierzându-se astfel din informație utilă. Pentru această situație, s-a realizat conversia din spațiul standard RGB la spațiul LAB [8]. Canalul L conține informație despre luminanța imaginii, în timp ce componentele A și B conțin informație despre culori. Am aplicat funcția de

egalizare a histogramei CLAHE(Contrast Limited Adaptive Histogram Equalization), ce acționează la nivel local. Împarte imaginea în mai multe regiuni și îmbunătățește la nivel local contrastul. Această operație a fost aplicată strict pentru canalul L corespunzător nivelului de luminanță. Am convertit imaginea înapoi la spațiul RGB, pentru a obține imaginea originală. Acest algoritm corectează variațiile de iluminare menționate anterior, structurile leziunilor și a microanevrismelor devenind mai clare.

Sucesiunea de pre-procesări la care au fost supuse eșantioanele setului de date pot fi vizualizate în figura 3.5.




Figura 3.5. Sucesiunea de pre-procesări aplicate asupra imaginilor brute

În figura 3.5 se poate constata faptul că funcția de decupare aplicată în prima etapă asupra fotografiilor fundoscopice are un efect minimal, dat fiind faptul că imaginile din seturile de date sunt deja bine încadrate. Aplicarea măștii circulare vizibilă în etapa a 3-a are un efect benefic vizual, elementele din marginile extreme devenind vizibile. Transformata CLAHE din ultima etapă îmbunătățește semnificativ aspectul fundalului, vizibilitatea micro-anevrismelor, totalitatea detaliilor fiind reliefate din punct de vedere vizual.

3.2.2 Algoritmul de pre-procesare Ben Graham

În urma analizării literaturii de specialitate, am descoperit faptul că în cadrul competiției disputate în anul 2015 pe platforma Kaggle, câștigătorul competiției a aplicat o pre-procesare ce îi poartă numele, bazată pe substracția mediei locale, cunoscută drept normalizare Ben Graham [9].

Această funcție izolează canalul verde din spațiul RGB, oferind un contrast maxim între rețeaua capilarelor, microanevrisme și fundalul roșu al retinei. Pentru imaginea generată, se va aplica un filtru de tip gaussian proporțional cu dimensiunea imaginii. Astfel, se va realiza diferența dintre

pixelul imaginii originale și cel mediat, pentru care se va aduna o constantă de 128 pentru a centra distribuția pixelilor la un nivel de gri mediu, precum se poate observa și în formula:

$$I_{out}(x,y) = 4 \cdot I_G(x,y) - 4 \cdot \text{GaussianBlur}(I_G, \sigma) + 128$$

$I_{out}(x,y)$ – Imaginea de ieșire

$I_G(x,y)$ – Imaginea inițială

σ – Varianța imaginii, este egală cu lungimea imaginii împărțită la valoarea 30

În ceea ce privește etapa pre-procesărilor, din cauza adăugării valorii constante de 128 prezente în zonele uniforme, fundalul imaginii primește informație redundantă pe care rețeaua o poate interpreta ca fiind utilă în detecția anomaliilor prezente în cazul retinopatiei. Este esențial ca în urma aplicării transformatei Ben Graham, masca să fie aplicată la ultimul pas, pentru a ignora complet fundalul imaginii și a păstra doar informația specifică de la nivelul ochiului. Figura 3.6 ilustrează faptul că în urma aplicării pre-procesării Ben Graham, vasele de sânge, cât și detaliile fine din imagine sunt conturate într-un mod expresiv. Nuanțele roșiatice sunt suprimate, pentru a evidenția exclusiv structura capilarelor nervoase. Întrucât rețeaua primește la intrare 3 canale, am multiplicat canalul verde de 3 ori, imaginea fiind reprezentată monocromatic.




Figura 3.6. Demonstrație vizuală pre-procesare Ben Graham

3.2.3 Algoritmul de pre-procesare Shades-of-Gray + CLAHE

O altă pre-procesare utilizată este reprezentată de combinația dintre Shades-of-Gray [10], urmată de operația CLAHE pentru a îmbunătăți contrastul local. Pe baza normei Minkowski [10] a intensității pixelilor, se va estima culoarea sursei de lumină. Formula generală a normei e este dată de ecuația:

$$e = \left(\frac{1}{N} \sum_{x,y} |F(x,y)|^p \right)^{\frac{1}{p}}$$

p – constantă uzual inițializată cu valoarea 6

$F(x,y)$ – valorile fiecărui pixel din imagine

e – culoarea iluminantului estimat

Imaginea este împărțită la valoarea iluminantului pentru a obține culori neutre, scopul algoritmului fiind de a normaliza culorile prezente la nivelul pozelor fundoscopice. Odată ce culorile au fost standardizate, am convertit spațiul imaginilor RGB în spațiul LAB, mai apoi am aplicat identic operația CLAHE pentru componenta L din spațiul LAB, trecând înapoi în spațiul RGB. Această pre-procesare poate fi vizibilă în figura 3.7.




Figura 3.7. Succesiunea de pre-procesări Shades-of-Gray + CLAHE aplicate asupra unei imagini de tip fund de ochi

Figura 3.7 confirmă faptul că pentru imaginile brute primite în format RGB se va izola zona de interes prin aplicarea unei măști de contur, metodă utilizată și în algoritmi precedenți. Prin aplicarea algoritmului Shades-of-Gray, culorile vor fi standardizate, rezultatul fiind tot o imagine în format RGB cu un balans corect de alb. Asupra acestei imagini se va aplica în mod identic algoritmul CLAHE pentru componenta L, după ce s-a realizat trecerea de la spațiul clasic RGB la spațiul LAB. În urma aplicării CLAHE, imaginea a fost trecută înapoi în spațiul RGB.

3.3 Augmentări utilizate

În sarcinile de Computer Vision, este necesar ca modelul să aibă o capacitate mare de generalizare pe baza datelor de antrenare. Utilizând informația extrasă din lotul de antrenament, este necesar să se poată înregistra rezultate optime pentru noi seturi de date din lotul de validare și de testare [11]. În caz contrar, când rețeaua nu poate obține rezultate optime pentru date neîntâlnite, se creează fenomenul de supraînvățare.

Există diverse tehnici de regularizare precum Dropout, normalizarea la nivel de lot, învățare prin transfer [11], ce previn apariția fenomenului de supraînvățare. Augmentarea datelor abordează problema suprapotrivirii la nivel de set de date, astfel încât aplicând transformări se va introduce

informație adițională prin tehnici de distorsionare a datelor, cât și prin supraeșantionare (se vor genera noi eșantioane de antrenament) [11].

Au fost aplicate augmentări din 3 clase distincte, pentru a oferi cât mai multă informație adițională setului de antrenare.

Transformări geometrice (Transformări afine)

În cazul recunoașterii unor aspecte cheie la nivelul unor imagini fundoscopice precum forma maculei, a capilarelor nervoase, a microanevrismelor, sunt necesare transformări geometrice pentru a evita situația în care rețeaua poate învăța pozițiile leziunilor la nivelul fiecărei imagini din setul de antrenare.

O primă transformare se bazează pe oglindirea pe direcție verticală și orizontală a imaginilor [11]. Oglindirea orizontală este critică pentru a forța modelul să nu se concentreze asupra unor caracteristici de formă pentru ochiul stâng relativ la ochiul drept, ci asupra conținutului exclusiv al imaginii.




Figura 3.8. Aplicare transformată de tip oglindire orizontală asupra imaginii

În figura 3.8, se poate observa vizual efectul oglinirii asupra imaginilor fundoscopice. Imaginea va fi simetrică față de axa sa verticală de referință.

S-au aplicat rotații aleatoare [11] sub diferite unghiuri (în intervalul $[-360^\circ, 360^\circ]$), ce aliniază caracteristicile fotografiilor la diverse unghiuri. Leziunile pot apărea la diverse orientări, iar aplicarea unei transformări previne modelul să învețe caracteristici generale legate de aliniere.




Figura 3.9. Aplicare transformare de rotație cu un unghi de 45° asupra imaginii originale

În figura 3.9, se poate identifica aspectul unui eșantion asupra căruia s-a aplicat o operație de rotație.

O altă transformare afină se concentrează pe scalarea și redimensionarea [11] fotografiilor fundoscopice, ce previne rețeaua să se bazeze pe distanța dintre aparatul focal și ochiul pacientului pentru a oferi verdictul final. Indiferent de mărimea leziunilor, rețeaua trebuie să identifice corect aspectul și forma acestora.




Figura 3.10. Aplicare transformare de scalare cu o rată supraunitară de 1.3 asupra imaginii originale

Transformări în spațiul de culoare

Sunt necesare ajustări ale punctelor de culoare, precum funcții de calibrare a luminozității și al contrastului [11], pentru a asigura faptul că modelul nu se bazează pe intensitatea luminoasă a unei imagini pentru a da verdictul unui pacient bolnav [12]. Formula ce determină modificarea luminozității de la nivelul imaginii este dată de relația [12]:

$$I'(x,y)=I(x,y)+\delta, \text{ unde}$$

$I(x,y)$ – valorile inițiale ale pixelilor

δ – factor de perturbare a luminozității (valorile pozitive luminează imaginea, cele negative o întunecă)




Figura 3.11. Aplicare transformată de iluminare, cu un factor de perturbare egal cu 60

În figura 3.11 se observă faptul că imaginea va avea valori mai ridicate. Este necesară introducerea unei limitări de contrast, pentru a păstra valorile pixelilor în gama de valori specifică afișării.

Calibrarea contrastului se efectuează pe baza formulei [12]:

$$I'(x, y) = \bar{I} + c \cdot (I(x, y) - \bar{I}), \text{ unde}$$

$\bar{I}$ – intensitatea medie a imaginii

$I(x, y)$ – valorile inițiale ale imaginii

c – factor de scalare ($c > 0$ contrastul crește, $c < 0$ contrastul scade)

$I'(x, y)$ – intensitatea rezultată




Figura 3.12. Aplicare transformată de contrast, cu un factor de scalare $c=1.8$, intensitatea medie egală cu 128

Figura 3.12 reliefează contrastele de la nivelul imaginii inițiale, pentru a asigura faptul că valoarea contrastului inițială nu va reprezenta o modalitate de caracterizare a afecțiunii.

Asupra imaginilor s-a injectat zgomot de natură Gaussiană independent distribuit extras dintr-o distribuție normală $\mathcal{N}(0, \sigma^2)$ pentru fiecare pixel al imaginilor din lotul de antrenare. Ulterior, este necesară limitarea valorilor modificate de zgomot pentru a nu depăși gama valorilor specifice nivelurilor generice de gri 0-255 [13].




Figura 3.13. Aplicare zgomot gaussian independent de dispersie 30

În figura 3.13 se observă faptul că aplicarea unui zgomot aditiv gaussian a distorsionat imaginea, creând un efect de granulație.

Transformări bazate pe ștergere aleatoare

Prin această metodă, se vor masca regiuni din imagine [11], astfel încât modelul va evita să se bazeze pe un anumit tip de leziune, fiind forțat să se concentreze asupra mai multor aspecte cheie.




Figura 3.14. Eliminare în mod aleator a porțiunilor din imagine

Analizând figura 3.14, se observă faptul că anumite regiuni au fost acoperite. Modelul trebuie să se concentreze asupra mai multor detalii ce indică anumite etape de dezvoltare a afecțiunii.

A existat posibilitatea aplicării mai multor tipuri de augmentări asupra unui eșantion din lotul de antrenare. În figura 3.15 se pot remarca diverse configurații ce s-au aplicat asupra unei imagini din lotul aferent antrenării.

Analiza Stocastică a Augmentărilor (Albumentations) Imagine: 2561_left.jpg




Figura 3.15. Tipuri de augmentări aplicate asupra unei imagini pre-procesate Ben Graham din cadrul setului de test

3.4. Modele Utilizate

Pe baza literaturii de specialitate efectuată, două dintre cele mai utilizate modele pentru care s-au înregistrat performanțe optime au fost ResNet, respectiv EfficientNet.

3.4.1. Modelul Residual Networks(ResNet)

În cadrul aplicațiilor bazate pe imagistică computațională, precum analiza și clasificarea imaginilor, procesarea limbajului natural, detecția anomaliilor, a sistemelor de recomandare, se utilizează modele bazate pe rețele convoluționale [5]. Convoluția este operația matematică ce stă la baza acestor tipuri de rețele, presupunând glisarea unei ferestre peste o matrice de valori inițiale, iar ulterior se efectuează suma ponderată a pixelilor aflați la intrare. Un avantaj principal al rețelelor convoluționale față de rețelele neuronale clasice este dat de numărul mai mic de parametri utilizați, totodată fiind mai eficiente în a învăța anumite caracteristici extrase dintr-o imagine, menținând pozițiile inițiale ai pixelilor din imagine.

Modelele bazate pe rețele neuronale au prezentat o evoluție accelerată pe parcursul ultimilor ani. Printre primele modele apărute se pot evidenția cele provenite din familia LeNet, primul model debutând în anul 1989 [14]. În componența sa se puteau număra 2 straturi convoluționale și 3 straturi complet conectate, în total având aproximativ 61000 de parametri. Pe măsură ce rețelele au evoluat, modelele au ajuns la zeci sau chiar sute de straturi, numărul de parametri ajungând la ordinul zecilor de milioane. [14] Această complexitate ridicată a numărului de straturi a atras după sine anumite dezavantaje, printre acestea remarcându-se anularea gradientilor în timpul procesul de învățare. În procesele de inferență, gradientii vor tinde către zero, iar performanțele modelului vor atinge un nivel de saturație, înregistrând treptat o scădere [15].

O bună soluție pentru a evita această problemă a fost implementarea rețelelor reziduale, pentru a face posibilă modificarea eficientă a ponderilor în cazul rețelelor adânci. Astfel, în loc de a solicita straturile convoluționale să învețe direct o anumită reprezentare, acesta va învăța treptat modificările ce trebuie făcute pentru a ajunge la reprezentarea finală prin intermediul blocurilor reziduale. Datele de intrare vor fi transmise nemodificate, fiind adunate element cu element la ieșirea straturilor suprapuse [16].




Figura 3.16. Reprezentarea unei conexiuni reziduale. Sursa [16]

Din punct de vedere matematic, putem considera funcția $H(x)$ ca fiind funcția obiectiv pe care rețeaua o va aproxima. Conform figurii 3.16, se va nota cu variabila x vectorul de intrare, iar funcția $F(x)$ va reprezenta transformarea neliniară realizată de stiva de straturi convoluționale. Cu ajutorul

conexiunii reziduale, ieșirea $H(x)$ se va exprima ca suma dintre ieșirea straturilor și a legăturii reziduale, scrisă ca $H(x)=F(x)+x$. Cu toate că structura rețelei va avea un aspect mai complex, principalul avantaj este reprezentat de eficiența acesteia. Conexiunile de identitate nu vor adăuga complexitate de calcul adițional. Acestea nu li se alocă ponderi, iar numărul de parametri ai rețelei rămâne nemodificat [16].

În ceea ce privește nivelul de optimizare, este mai ușor de optimizat funcția împreună cu legătura de reziduu decât funcția originală. Chiar și în anumite situații limită, în care funcția optimă este egală cu funcția identitate, este mult mai simplu pentru rețea să reducă reziduul $F(x)$ către 0, decât să se ajusteze totalitatea straturilor neliniare să tindă către funcția identitate [16].

Rețelele de tip ResNet pot fi grupate în mai multe categorii, în funcție de numărul acestora de straturi. ResNet18 și ResNet34 sunt compuse din blocuri reziduale simple cu o complexitate mai redusă. Sunt utilizate pentru aplicații cu un număr limitat de resurse, sau pentru implementări ce utilizează un set de date restrâns. Pe de altă parte, rețeaua ResNet50 utilizează 3 straturi convoluționale, permițând arhitecturii să fie mai adâncă fără a introduce complexitate computațională adițională. Este una dintre cele mai populare arhitecturi ce utilizează rețele convoluționale. Poate fi utilizată pentru aplicații complexe de imagistică computațională, fiind capabil să reliefeze detalii semnificative din cadrul imaginilor. Rețeaua ResNet101 utilizează aceeași structură a blocurilor reziduale precum ResNet50, însă numărul acestora crește semnificativ. Este utilizat pentru aplicații complexe, fiind capabil să proceseze seturi largi de date. Ca și principal dezavantaj se poate menționa faptul că această arhitectură prezintă un cost computațional ridicat, comparativ cu arhitecturile ResNet menționate anterior [17].




Figura 3.17. Structură de tip Basic Bloc. Sursa [18]

În figura 3.17 se poate identifica structura unui bloc rezidual din cadrul arhitecturii ResNet34, cunoscut și sub denumirea de Basic Bloc [16]. Fiecare stivă are în componența sa 2 straturi convoluționale cu filtre de dimensiune 3x3 și utilizează o legătură de salt de tip funcție identitate. După fiecare strat convoluțional se utilizează funcția ReLU de activare [16]. Spre deosebire de celelalte funcții neliniare, avantajul major este dat de viteza acesteia de convergență, modelele ce utilizează această funcție de activare antrenându-se mult mai rapid datorită lipsei unei limite inferioare [5].




Figura 3.18. Componenta blocurilor de tip Residual Building Block. Sursa [19]

În figura 3.18 este ilustrată componenta unui bloc rezidual al structurilor ResNet avansate (precum ResNet50, ResNet101, Res2Net, ResNeXt), cunoscut sub denumirea de Bloc de Construcție Rezidual (Residual Building Block) [19]. În funcție de tipul rețelei și modul în care este reprezentată informația după ultimul strat convoluțional, se pot identifica două categorii ale Blocurilor de Construcție Reziduale. Figura 3.18a) ilustrează faptul că în componenta blocului RBB-1 există 3 straturi convoluționale ce sunt însoțite de normalizări ale loturilor de date, cu scopul de a stabiliza procesul de inferență, iar în același timp distribuția datelor va fi de tip distribuție Gaussiană, de medie 0 și dispersie 1. După fiecare etapă de convoluție se remarcă utilizarea funcției de activare ReLU pentru a accelera procesul de învățare. Cele 3 operații de convoluție se vor efectua cu ferestre de dimensiunea 1×1 pentru primul strat (scopul principal al acestei operații este în principal de a modifica numărul de canale aflate la intrare), urmată de o fereastră de dimensiune 3×3 , iar ultimul strat revine la dimensiunea nucleului de 1×1 . Primul strat reduce dimensiunea numărului de trăsături. Stratul median cu dimensiunea de filtrare 3×3 procesează volumul de date ce a fost redus. La nivelul ultimului filtru, se generează numărul inițial de canale ce a fost redus, iar la ieșire se vor aduna numărul trăsăturilor rezultate cu cele provenite din rețeaua de salt [16]. Blocul de tip RBB-1 este folosit în special în arhitecturi de tip ResNet50, ResNet101 și ResNet152. Structurile RBB-1 și RBB-2 sunt similare, cu excepția legăturii de salt care poate fi atât funcția identitate, cum se poate observa în figura 3.18a), sau poate avea în componentă sa un strat convoluțional alături de un proces de normalizare al lotului de date. Structura din figura 3.18b) este utilizată în cadrul unor arhitecturi ResNet modificate precum Res2Net sau ResNeXt [19].

Pentru a clasifica imaginile fundoscopice în diferite etape ale retinopatiei diabetice, este necesar ca arhitectura utilizată să identifice numeroase detalii sugestive, precum aspectul maculei, forma și vascularizarea capilarelor nervoase cât și nuanțele de roșu din fundalul imaginii. Totodată, este necesar ca arhitectura să poată lucra cu un set mai larg de date, pentru a putea generaliza eficient rezultatele obținute. Pentru a efectua un echilibru între eficiență și putere computațională, am utilizat

rețeaua ResNet50, fiind unul dintre cele mai populare modele în aplicații de segmentare și clasificare a imaginilor medicale.

Arhitectura completă a modelului ResNet50 poate fi vizualizată în figura 3.19.




Figura 3.19. Arhitectura standard ResNet50. Sursa [20]

La intrarea rețelei se va introduce o imagine fundoscopică, iar la ieșire rețeaua va fi adaptată în așa fel încât imaginea să poată fi clasificată într-una dintre cele 5 stadii ale retinopatiei diabetice.

Fotografia va fi filtrată printr-un prim strat convoluțional de dimensiunea nucleului de 7×7 , având în total 64 de canale și un pas de valoare 2. Ulterior se va aplica operația de MaxPooling de 3×3 cu un pas de 2, pentru a reduce dimensiunea spațială a imaginii. Această structură mai e cunoscută și sub denumirea conv1 [20].

Mai apoi se reliefează prezența a 3 straturi convoluționale cu filtre de tip 1×1 și 64 de canale, urmate de un filtru de 3×3 și 64 de canale, precedat de un filtru de 1×1 și 256 de canale. Aceste 3 straturi vor forma un bloc convoluțional care vor avea la ieșire legătura de salt ce se conectează la intrarea primului filtru. Această structură bloc va fi repetată de 3 ori, fiind cunoscută drept conv2_x [20].

În următoarea etapă, se accentuează o nouă structură a blocurilor reziduale. De această dată, primul strat va conține un filtru de 1×1 și 128 de canale, urmat de un strat cu un nucleu 3×3 și 128 de canale. Ultimul strat va conține un filtru asemeni primului de tip 1×1 , dar va avea în schimb 512 canale, păstrând modificările la nivelul imaginii intacte, modificând numărul canalelor. Aceasta structură în cadrul modelului ResNet se repetă de 4 ori și reprezintă componenta conv3_x [20]. Ca și în cazul precedent intrarea primului strat și ieșirea ultimului vor fi conectate.

Ulterior se identifică 6 blocuri identice repetitive, primul filtru efectuează operația de convoluție cu un filtru de dimensiunea 1×1 , redimensionând fotografia la 256 de canale. Următorul strat realizează convoluția cu o fereastră 3×3 și păstrează numărul celor 256 de canale. Ultimul strat convoluțional conține un filtru de tip 1×1 și mărește numărul canalelor la 1024. La nivelul rețelei, totalitatea acestor blocuri reprezintă conv4_x [20].

Structura ultimelor 3 blocuri ce se identifică în arhitectura ResNet50 până la operația de vectorizare, denumită conv5_x, prezintă în componență un filtru de dimensiune 1×1 și 512 canale, urmat de un filtru 3×3 și 512 canale, iar ultimul prezintă o fereastră de dimensiune 1×1 și 2048 de canale [20].

În urma tuturor acestor filtrări, se va aplica o operație de mediere (Average Pooling). Cele mai multe straturi ascunse din structura rețelei utilizează operații de normalizare a lotului pentru a aduce trăsăturile în aceeași gamă de valori, iar ca și funcție de activare se utilizează funcția ReLU. La ieșire s-a utilizat funcția de activare softmax ce transformă scorurile obținute în probabilități asociate fiecărei clase. Ultimul strat poate fi modificat în funcție de clasificarea pe care fiecare utilizator dorește să o implementeze [20].

Avantajele rețelelor de tip ResNet sunt numeroase, acestea reușind să mențină gradientii stabili în procesul de învățare, permițând antrenarea rețelelor ce pot avea sute de straturi. Totodată, acestea și-au dovedit eficiența în numeroase aplicații ale clasificărilor de imagini, reușind să capteze foarte bine detaliile fine din cadrul fotografiilor. Cu toate acestea, se pot remarca și o serie de dezavantaje ale rețelei. Se evidențiază faptul că rețelele ResNet50 în momentul în care nu dispun de volume de date suficient de mari, pot memora zgomotele și detaliile mai puțin semnificative ale fotografiilor, fiind predispuse la procesul de supraînățare. Astfel, trebuie să existe o concordanță între complexitatea rețelei și volumul datelor furnizate. O altă inconveniență este exprimată de incompatibilitatea rețelei cu anumiți algoritmi de optimizare, fapt deseori observat în cazul rețelelor ce dispun de un număr ridicat de straturi [5].

3.4.2. Modelul EfficientNet

O abordare clasică pentru a îmbunătăți acuratețea rețelelor convoluționale se bazează pe procesul de scalare. Scalarea rețelelor se realizează în adâncime, lățime, sau pe baza rezoluției imaginii. Acest procedeu se poate realiza pe toate cele trei dimensiuni în mod simultan, fiind necesar ca acest proces de scalare să fie ajustat cu atenție, de cele mai multe ori scalările arbitrare ducând la rezultate sub-optimale [21].

În cadrul arhitecturilor de tip EfficientNet, s-a realizat o scalare uniformă după cele 3 dimensiuni menționate anterior, fapt ce poate fi vizualizat în figura 3.20.




Figura 3.20. Realizarea scalărilor după cele 3 dimensiuni prezentate (lățime, adâncime, rezoluție). Sursa [21]

Pentru a rezolva problema scalării s-au utilizat numeroase abordări. Din punct de vedere matematic, un strat i se poate defini ca o funcție $Y_i = F_i(X_i)$, unde F_i este operatorul, Y_i este vectorul de la ieșire, iar X_i este vectorul de intrare, de forma (H_i, W_i, C_i) , unde H_i, W_i reprezintă dimensiunea spațială, iar C_i este dimensiunea canalului de intrare. O rețea convoluțională N se poate defini ca o combinație de

straturi compuse $N=F_1 \odot F_2 \odot F_3 \odot \dots \odot F_n = \odot_{j=1 \dots k} F_j (X_{(H,W,C)})$ [21]. Prin scalarea modelului, se dorește extinderea dimensiunilor H , W și C , fără a modifica operatorul F_i . Adicional, pentru a descoperi cea mai bună scalare fără a destabiliza modelul, s-a dorit scalarea cu un factor constant, obiectivul devenind rezolvarea unei probleme de optimizare: $\max \text{Accuracy}(N(d, w, r))$ [21].

d, w, r

Dificultatea acestei probleme este dată de faptul că cele 3 variabile d, w și r depind unele de celelalte. Din această cauză, în cadrul multor rețele scalarea s-a efectuat după o singură dimensiune dintre cele 3, ceea ce a îmbunătățit performanțele modelului, însă pentru modelele mai adânci se va concretiza o saturare a acurateții [21]. Astfel, din cauza faptului că există constrângeri între dimensiuni, trebuie utilizată o abordare care să echilibreze dimensiunile de scalare. Pentru arhitectura EfficientNet, s-a realizat o scalare compusă ce utilizează un coeficient compus ϕ . Astfel, dimensiunile principale vor fi de forma: $d=\alpha^\phi$, $w=\beta^\phi$, $r=\gamma^\phi$, unde α , β , γ sunt constante supraunitare ce respectă constrângerea $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. Coeficientul ϕ controlează câte resurse sunt disponibile pentru scalarea modelului, iar parametrii α , β , γ indică câte resurse sunt alocate pentru a scala parametrii specifici lățimii, adâncimii, și rezoluției. Numărul de operații FLOPS este direct proporțională cu relația $\alpha \cdot \beta^2 \cdot \gamma^2$. Orice nou ϕ , numărul de operații va crește cu 2^ϕ [21]. Determinarea celor mai bune valori pentru hiperparametrii α , β , γ , ϕ , a divizat problema în 2 etape.

În etapa 1 parametrul ϕ a fost inițializat cu valoarea $\phi=1$, descoperindu-se faptul că cele mai bune valori obținute sunt $\alpha=1.2$, $\beta=1.1$, $\gamma=1.15$, abordare tipică în cadrul rețelei EfficientNet-B0.

În etapa a 2-a, au fost fixați coeficienții α , β , γ , scalând cu diferite valori pentru ϕ , pentru a obține rețelele EfficientNet-B1-B7.

În cadrul arhitecturii EfficientNet, s-a dorit optimizarea acurateții și a numărului de operații realizate de către modelul m , astfel încât s-a încercat optimizarea relației $\text{ACC}(m) \times [\text{FLOPS}(m)/T]^w$. ACC reprezintă acuratețea modelului, FLOPS indică numărul de operații efectuate, T reprezintă numărul țintă de operații FLOPS, iar w este un hiperparametru ce are valoarea -0.07. Astfel, soluția obținută a condus la apariția primei rețele de tip EfficientNet, a cărei țintă inițială a fost realizarea a 400 de milioane de operații. Arhitectura poate fi vizualizată în figura 3.21.

Stage i	Operator $\hat{F}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	#Channels $\hat{C}_i$	#Layers $\hat{L}_i$
1	Conv3x3	224×224	32	1
2	MBConv1, k3x3	112×112	16	1
3	MBConv6, k3x3	112×112	24	2
4	MBConv6, k5x5	56×56	40	2
5	MBConv6, k3x3	28×28	80	3
6	MBConv6, k5x5	28×28	112	3
7	MBConv6, k5x5	14×14	192	4
8	MBConv6, k3x3	7×7	320	1
9	Conv1x1 & Pooling & FC	7×7	1280	1

Figura 3.21. Arhitectura rețelei EfficientNet-B0. Sursa [21]

Pe baza articolelor studiate, pentru problemele de natură medicală cea mai potrivită rețea din familia EfficientNet este EfficientNet-B3. Prezintă aceeași adâncime precum EfficientNet-B0, dar de

1.3 ori mai multă lățime, respectiv 1.2 ori mai multă rezoluție [22]. În structura rețelelor de tip EfficientNet, se remarcă blocuri de tip MBConv [23], cât și utilizarea conexiunilor de tip rezidual, prezente și în arhitectura ResNet. Un bloc de tip MBConv este alcătuit din următoarele componente:

- Un strat convoluțional cu un nucleu de tip 1x1, pentru a crește numărul de canale
- Un strat ce efectuează operația de convoluție în adâncime pentru fiecare canal
- Modulul Squeeze-and-Excitation(SE), ce funcționează asemeni unui mecanism de atenție pentru anumite canale ale rețelei [24].
- Un strat convoluțional cu un nucleu de tip 1x1 pentru a reduce numărul de canale. Hărțile de caracteristici vor fi comprimate
- Normalizarea lotului(Batch Normalization), cât și funcția de activare de tip Swish [23]

Matematic, aceste operații se pot transcrie astfel:

$$Output = Swish (BatchNorm (Conv_{1 \times 1} (DepthwiseConv(Conv_{1 \times 1}(Input)))) [23]$$

Funcția de activare Swish introduce neliniaritate în ceea ce privește extragerea caracteristicilor. Această funcție se poate defini cu ajutorul formulei:

$$Swish(x) = x \times \text{sigmoid}(x)$$

Blocul Squeeze-and-Excitation permite rețelei să efectueze o recalibrare adaptivă a canalelor, învățat să accentueze caracteristicile utile și să suprimă zgomotul. Acest mecanism de bază are 3 operații distincte:

1. Squeeze: Informația va fi comprimată prin intermediul stratului de mediere GlobalAveragePooling într-un descriptor de canal. Fiecare canal va fi comprimat prin intermediul relației:

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j)$$

Se vor aduna elementele fiecărui canal, care mai apoi vor fi normate la dimensiunea acestuia [24].

2. Excitation: Pe baza vectorului global extras, se vor genera scoruri de importanță pe baza formulei:

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1 z)) [24]$$

W_{1z} - Reduce dimensionalitatea vectorului extras z pe baza unui factor de reducere a dimensionalității r .

Funcția de activare $\text{ReLU}(\delta)$ – Introduce neliniaritate prin suprimarea valorilor negative

W_2 – Crește dimensionalitatea la numărul inițial de canale C

Funcția de activare Sigmoid σ – Transformă toate valorile în numere cuprinse în intervalul $[0,1]$, pentru a genera scoruri de importanță pentru fiecare canal.

3. Scale: Ieșirea finală a blocului se obține prin multiplicarea directă, canal cu canal, între harta de caracteristici inițială și scalarul de activare corespunzător [24].

Acest bloc include și o conexiune de tip rezidual, ce poate fi reprezentată cu ajutorul relației:

$$\text{Output} = x + \text{Conv1} \times 1(\text{DepthwiseConv}(x)) \quad [23]$$

Arhitectura rețelei EfficientNet-B3 este reprezentată în figura 3.22. La intrare, rețeaua primește imagini de dimensiune 300×300 pixeli, cât și 3 canale de culoare. Se aplică un filtru convoluțional de dimensiune 3×3 , pentru a extrage trăsături vizuale primare. Dimensiunile spațiale se vor reduce la 112×112 pixeli, în timp ce adâncimea canalelor va crește la 40. În structura rețelei se remarcă 2 tipuri de blocuri, MBConv1, respectiv MBConv6 [22]. MBConv1 indică faptul că la nivel intern nu există expansiune a canalelor atunci când se aplică operația de convoluție, în timp ce pentru blocul MBConv6 canalele se vor multiplica de 6 ori pentru a oferi mai multă informație. Operația de convoluție se realizează atât cu nuclee de tip 3×3 , pentru a extrage detalii cât mai fine, filtrele de tip 5×5 extrapolând detalii generale. Conexiunea reziduală ce este evidențiată la nivelul anumitor blocuri din rețea are rolul de a preveni atenuarea gradientului, în așa fel încât modelul să poată învăța noi caracteristici pe măsură ce arhitectura devine din ce în ce mai adâncă.




Figura 3.22. Arhitectura rețelei EfficientNet-B3. Sursa [22]

3.5. Metode de Antrenare și Optimizare a Modelului

3.5.1. Învățare prin transfer și Strategia de Adaptare Fină

Obținerea rezultatelor optime înregistrate de model pe baza datelor de antrenare implică adaptarea ponderilor interne în mod corespunzător. Modul în care procesul de antrenare are loc precum și adaptarea modelului la setul de date utilizat prezintă o importanță deosebită în cadrul problemei de clasificare a etapelor de severitate a retinopatiei diabetice.

În cadrul procesului de antrenare al rețelelor neuronale, antrenarea de la zero a modelului nu ar fi posibilă din cauza setului limitat al lotului de antrenare. Insuficiența datelor ar face imposibil procesul de convergență al ponderilor, în multe situații producându-se fenomenul de supraînvățare al lotului de antrenare. Conform literaturii de specialitate s-a constatat faptul că în majoritatea problemelor de clasificare, rețelele au fost preantrenate pe diverse seturi de date, cea mai comună bază de date fiind ImageNet [21]. Utilizând tehnica de Transfer Learning [21], aceasta presupune ca pe baza cunoștințelor acumulate în urma etapei de preantrenare, ponderile sunt adaptate astfel încât rețeaua este capabilă să detecteze aspecte precum muchii, culori, forme, texturi la nivelul unor imagini.

Nu este suficientă utilizarea exclusivă a unei arhitecturi preantrenate pe setul de date ImageNet (menit să detecteze clase generice precum animale sau vehicule) pentru a rezolva o problema de clasificare a datelor medicale. Este necesar ca ponderile să fie ajustate fin printr-o practică cunoscută în literatură drept Fine-Tuning [25]. Astfel, modelul va fi calibrat progresiv de la ieșirea acestuia către straturile de intrare, pe baza erorii calculate. Acest proces este benefic chiar și pentru situația în care setul de date este restrâns [25]. Pentru problema clasificării retinopatiei, ponderile vor fi ajustate pentru a detecta microanevrisme, leziuni, capilare, ramificații neobișnuite.

3.5.2. Dinamica Hiperparametrilor: Dimensiunea Lotului și Epocile de Învățare

Pe parcursul etapei de antrenare, eșantioanele vor fi grupate în loturi distincte. Alegerea dimensiunii lotului reprezintă un hiperparametru empiric. Un lot numeros va reduce semnificativ timpul de calcul al rețelei, însă procesul de actualizare a ponderilor va avea nevoie de mai multe epoci de învățare pentru a atinge punctul minim al erorii [26]. În altă ordine de idei, gruparea datelor într-un lot restrâns va indica o convergență rapidă spre minim. Rețeaua va corecta și va actualiza mai des, în această situație procesul de învățare devenind mai „zgomotos”. Cu toate că vor fi necesare mai puține epoci pentru a atinge performanțe optime, din punct de vedere computațional este mult mai solicitantă utilizarea unui lot redus în procesul de antrenare. Conform cercetătorului Yoshua Bengio [26], alegerea implicită a unui lot de dimensiune 32 reprezintă o valoare de start potrivită, ce poate fi ulterior reglată în funcție de rezultatele experimentale obținute.

Numărul de epoci reprezintă un hiperparametru crucial în cadrul învățării. Epoca se poate defini ca trecerea completă a algoritmului peste întreg setul de date ales de către utilizator [27]. Parametrii rețelei reprezentați de ponderi și deplasări vor fi inițializați în mod aleator. Când se efectuează ciclul următor de simulare, parametrii se vor modifica corespunzător cu scopul de a reduce

eroarea și a îmbunătății acuratețea globală. În momentul inițializării, trebuie luate în calcul efectele de subînvățare și supraînvățare. Pe de o parte, subînvățarea are loc atunci când modelul nu atinge performanțele dorite pentru datele de antrenare, implicit rețeaua nu poate generaliza corect ceea ce a învățat pentru un set de date nou [27]. Pe de altă parte, supraînvățarea indică faptul că atât datele de antrenare, cât și zgomotele aferente au fost reținute de către model. Metricile de performanță vor indica valori foarte bune pentru lotul de antrenare, cu toate acestea rețeaua nu poate generaliza ceea ce a învățat, acuratețea modelului scăzând semnificativ pentru un nou lot de date. De regulă, un număr mic de epoci rezultă în apariția procesului de subînvățare, în timp ce un număr ridicat poate introduce supraînvățarea modelului [27].

Alegerea ratei de învățare optim este puternic influențată de dimensiunea lotului în care am grupat fotografiile, existând o corelație puternică între cei doi hiperparametri. De regulă, pentru o dimensiune a lotului mai mică, se va impune ca și rata de învățare să ia valori reduse, pentru a atinge performanțe optime.

3.5.3. Strategii de Regularizare

Pentru a evita situația în care rețeaua nu este capabilă să potrivească informația extrasă din setul de antrenare pentru noi date întâlnite, utilizarea unor tehnici de regularizare constituie o practică empirică în cadrul etapei de antrenare.

În majoritatea articolelor ce relatează modul în care au fost abordate clasificări de natură medicală, au fost identificate numeroase tehnici de regularizare ce au fost ulterior abordate în arhitectura proiectului.

La ieșirea rețelei se va aplica un strat adițional denumit GlobalAveragePooling2D [28], ce realizează operația de mediere la nivelul fiecărei hărți generate la ieșirea rețelei, cu scopul de a preveni fenomenul de supraînvățare. Altfel spus, se realizează o compresie a numărului de parametri, iar rețeaua va deveni mult mai eficientă din punct de vedere al resurselor computaționale utilizate. Riscul de supraînvățare a datelor de antrenare va fi mai mic.

Ulterior, s-a aplicat o tehnică de regularizare de tip Dropout pentru a anula aleator anumiți neuroni din numărul total pe parcursul procesului de învățare. În momentul în care se rulează datele de validare și cele de testare, efectul acestui strat nu va mai funcționa. Astfel, la fiecare epocă, modelul va fi forțat să învețe noi caracteristici diferite de cele precedente [29].

O altă tehnică des utilizată în articole de specialitate este Early Stopping, aplicat pentru setul de validare. Pe baza loss-ului calculat pentru setul de validare extras, se oprește forțat procesul de antrenare în momentul în care pentru un număr de etape succesive eroarea va înregistra valori crescătoare, față de valoarea minimă obținută a celui mai bun model în cadrul procesului de antrenare. Astfel, este suprimat fenomenul de supraînvățare la care modelul poate fi supus, modelul salvat fiind cel care înregistrează cea mai redusă eroare [30], totodată datorită parametrului patience ce indică numărul de epoci succesive pentru care procesul va fi stopat în cazul în care nu se remarcă nicio îmbunătățire, algoritmul nu va opri antrenarea pentru mici fluctuații de câteva epoci înregistrate, permițând în continuare modelului să depășească minimele locale întâlnite. Din acest motiv,

utilizarea acestei metode permite alegerea numărului de epoci pentru etapa de antrenare să poată fi selectat în mod complet arbitrar.

Normalizarea la nivel de lot [31] este o tehnică des implementată în special în arhitectura internă a rețelelor neuronale. Pentru a rezolva problema distribuției inegale a datelor, ce încetinește procesul de învățare, normalizarea se va aplica pentru fiecare set de date, fiecare caracteristică va fi transformată în așa fel încât poate fi modelată ca o distribuție de tip Gaussiană de medie nulă și dispersie unitară. Pentru a nu restrânge astfel anumite caracteristici de bază, în mod adițional doi parametri de bază α , respectiv β ce reprezintă factorul de scalare și factorul de deplasare vor permite rețelei să redea forma originală a activărilor [31].

3.5.4. Funcții de Cost și adaptarea dezechilibrelor la nivelul claselor

Funcția de cost reprezintă modalitatea principală de evaluare a modelului, ce măsoară eroarea dintre predicțiile oferite de model și etichetele furnizate. Alegerea funcției de cost depinde foarte mult de natura problemei, iar în cazul problemelor de clasificare, funcția de cost cea mai des utilizată este funcția de entropie încrucișată [32]. În cazul clasificărilor binare, această funcție este definită sub forma:

$$CE(p, y) = \begin{cases} -\log(p) & \text{dacă } y = 1 \\ -\log(1 - p) & \text{în caz contrar.} \end{cases}$$

y – reprezintă clasa reală $y \in \{\pm 1\}$

p – probabilitatea estimată pentru clasa $y=1$, $p \in [0,1]$

Pentru situația în care clasificarea este multclasă, varianta adaptată a funcției de entropie încrucișată se poate scrie sub forma:

$$CE_{total} = \sum_{k=1}^K -[y_k \log(p_k) + (1 - y_k) \log(1 - p_k)], \text{ unde}$$

K - numărul de clase

y_k – valoarea reală pentru stadiul k , $y \in \{\pm 1\}$

p_k – probabilitatea prezisă de model pentru stadiul k , $p \in [0,1]$

În situația în care distribuția eșantioanelor din setul de antrenare este nebalansată, funcția de entropie încrucișată nu reușește să clasifice eficient clasele rare [32]. Este necesară o nouă funcție adaptată pentru a acorda ponderi diferite pentru fiecare clasă, definită drept Focal Loss [32]. Se va adăuga adițional un factor de modulare $(1 - p_t)^\gamma$, unde γ este un parametru ce poate fi reglat în funcție de modul în care sunt distribuite eșantioanele din lot [32]. Funcția va fi definită astfel:

$$FL(p_t) = -\alpha(1 - p_t)^\gamma \log(p_t)$$

În cazul în care parametrul γ devine nul, funcția Focal Loss va lua forma entropiei încrucișate. Pentru valori din ce în ce mai mari ale lui γ , efectul factorului de modulare va fi din ce în ce mai vizibil. Valoarea $\gamma = 2$ este valoarea standard utilizată [32], fiind adoptată și în implementarea proiectului.

Parametrul α este factorul de ponderare asimetric atribuit fiecărei clase [32]. Acesta a fost inițializat pentru a penaliza erorile înregistrate pentru stadiile avansate ale bolii. Uzual, acesta este

inițializat cu valoarea 1. Creșterea acestuia va determina modelul să fie mai agresiv cu predicțiile efectuate, pentru a minimiza numărul de pacienți fals-negativi înregistrați.

O metodă standard de regularizare ce însoțește funcția Focal Loss este utilizarea label smoothing [33], practică des utilizată în special în problemele de natură medicală, unde granița dintre severitatea pacienților bolnavi poate fi interpretabilă de către specialiști. Modelul va fi calibrat prin utilizarea unor etichete netezite în detrimentul celor absolute. Astfel, vectorul original va fi distribuit către toate clasele. Relația ce stă la baza aceste tehnici este:

$$y_k^{LS} = y_k(1 - \alpha) + \frac{\alpha}{K}$$

y_k – Eticheta originală

K – Numărul de clase

α – Parametrul de netezire

y_k^{LS} – Eticheta netezită

3.5.5. Algoritmul de optimizare și planificarea ratei de învățare

În cadrul metodologiei de antrenare a rețelelor neuronale, așa cum am relatat și anterior, se încearcă minimizarea funcției de cost pe baza unor algoritmi generici [26]. Matematic, acest concept poate fi modelat sub forma:

$$\arg \min_{\theta \in \mathbb{R}} L(\theta); \quad L(\theta) = \frac{1}{M} \sum_{i=1}^M L_i(\theta)$$

$L(\theta)$ – Funcția de cost medie

M – Dimensiunea setului de date

$L_i(\theta)$ – Funcția de cost calculată pentru o imagine

θ – Reprezintă toate ponderile și deplasările din rețeaua neuronală

Pe baza funcției de cost calculate, prin intermediul tehnicilor de optimizare ponderile rețelei vor fi ajustate corespunzător. În studiul experimental s-a utilizat exclusiv tehnica Adam de optimizare [26]. Ponderile vor fi actualizate conform relației:

$$w_t = w_{t-1} - \frac{\eta}{\sqrt{\hat{v}_t + \epsilon}} \cdot \hat{m}_t$$

Estimatorii $\hat{v}_t$, $\hat{m}_t$ sunt definiți prin relațiile:

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}, \text{ unde}$$

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \frac{\partial L}{\partial w_t}$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) \left[\frac{\partial L}{\partial w_t} \right]^2$$

$$\frac{\partial L}{\partial w_t} = \nabla_w C(w_t; x^{(B)}; y^{(B)})$$

β_1, β_2 - parametrii ce aparțin intervalului $[0,1]$ și reprezintă cantitatea de informație păstrată din actualizarea precedentă.

m_t – primul moment, reprezintă media mobilă a gradientilor

v_t – al doilea moment, media mobilă a gradientilor ridicată la pătrat

$\hat{v}_t, \hat{m}_t$ – media de tip unu și doi corectate de eroare

Hiperparametrul η reprezintă rata de învățare a modelului, ce indică dimensiunea pașilor cu care funcția de optimizare se va deplasa pe curba de cost. Pentru problema de optimizare, este necesar ca hiperparametrul ales să fie încadrat în niște valori clasice. Alegerea unei rate de învățare foarte mare va face ca algoritmul să convergă mai rapid, însă va sări peste minimele globale. O rată de învățare mică poate asigura convergența sigură, însă timpul de convergență va fi foarte mare. Așadar, o practică des utilizată constituie utilizarea unei rate de învățare care să poată varia, pentru a asigura convergența către minim într-un timp convenabil.

Tehnica ReduceLRonPlateau [11] reprezintă o metodă fundamentală de variație a ratei de învățare. În cazul în care modelul a extras totalitatea caracteristicilor, atingând un nivel de saturație ce poate fi vizibil prin faptul că acuratețea tinde să stagneze, iar funcția de eroare nu semnalează nicio îmbunătățire pentru un anumit număr de epoci consecutive, rata de învățare va fi redusă la jumătate din valoarea inițială. Astfel, ponderile interne vor fi reglate mai fin, pentru a converge către valoarea optimă. Această metodă permite setarea unei limite inferioare până la care rata de învățare poate fi reglată.

O altă funcție ce variază rata de învățare este cunoscută în literatură drept Super Convergence Cosine Annealing with Warm-Up [34]. Ajustarea ratei de învățare se va face în 2 pași: faza de încălzire(warm-up), ce presupune creșterea ratei de învățare până la o anumită valoare stabilită, urmată de etapa de scădere cosinusoidală, ce presupune descreșterea pasului de învățare. Utilizarea unei rate de învățare mici pentru primele etape este esențială pentru a stabiliza ponderile modelului, care în primele etape sunt inițializate în mod aleator.

În faza de încălzire, se va porni cu o rată de învățare mică ce va crește brusc după câteva epoci de antrenare. Relația ce modelează acest fenomen este:

$$\eta_{cur} = \eta_{init} - \frac{1}{2}(\eta_{max} - \eta_{init}) \left(\cos\left(\frac{T_{cur}}{T_{peak}} \pi\right) + 1 \right)$$

Numărul de epoci ce indică când rata de învățare va atinge valoarea maximă poate fi modificată de către utilizator.

În etapa de descreștere, rata de învățare va tinde către zero, pe măsură ce algoritmul se apropie de minimul funcției de cost. Formula utilizată pentru reducerea ratei de învățare este dată de ecuația:

$$\eta_{cur} = \frac{1}{2} \eta_{max} \left(\cos \left(\frac{T_{cur} - T_{peak}}{T_{total} - T_{peak}} \pi \right) + 1 \right)$$

η_{init} – Rata de învățare inițială pentru etapa de warm-up

η_{max} – Rata maximă de învățare pentru convergență rapidă

T_{peak} – Numărul epocii pentru care rata de învățare atinge cea mai mare valoare

T_{cur} – Epoca curentă

T_{total} – Numărul total de epoci de antrenare

Vizual, figura 3.23 accentuează modul în care rata de învățare variază pe parcursul procesului de antrenare.




Figura 3.23. Variația ratei de învățare pentru $T_{total}=160k$ epoci, $T_{peak}=40k$ epoci, iar $\eta_{max}=0.1$.
Sursa [34]

3.5.6. Clasificarea Multiclasă și Regresia Ordinală

Funcția de activare utilizată pentru ultimul strat al rețelei, ce conține cei 5 neuroni corespunzători celor 5 etape de clasificare este Softmax. Pe baza vectorului de valori obținut din ultimul strat al rețelei. Fiecare componentă a rețelei va fi normalată conform formulei:

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

z_i – componenta curentă a vectorului

K – numărul de clase

Astfel, fiecărei componente îi va fi asociată câte o probabilitate, cu condiția ca suma tuturor să fie egală cu 1.

Pentru problema retinopatiei, degradarea afecțiunii se realizează treptat, motiv pentru care o altă abordare implică clasificarea ordinală. Pentru fiecare clasă, problema va deveni de natură binară, astfel încât stratul final al rețelei va utiliza funcția de activare Sigmoid, în loc de Softmax. Fiecare

neuron trebuie să decidă dacă pacientul este cel puțin în etapa aferentă. De exemplu, eticheta pentru un pacient aflat în stadiul 3 va fi modificată din forma [0, 0, 1, 0, 0] în vectorul de progresie [1, 1, 1, 0, 0].

3.6. Metode de evaluare a modelului

Evaluarea Acurateții Globale

Pentru a evalua calitatea modelului, au fost utilizate o serie de măsurători distincte, bazate pe calculul acurateții generale, al metricilor extrase din matricea de confuzie, cât și a gravității confuziilor din punct de vedere medical.

În cadrul problemelor de clasificare, cea mai comună metrică de măsură este reprezentată de acuratețea globală, care este definită ca numărul de predicții corecte împărțit la numărul total de predicții efectuate de către model [20]. Matematic, această relație este definită cu ajutorul formulei:

$$\text{Acuratețe} = \frac{\text{Numărul de predicții corecte}}{\text{Numărul total de predicții efectuate}}$$

Pentru problemele de natură medicală, nu este suficientă evaluarea exclusivă a metricii de acuratețe, dat fiind faptul atât setul de test cât și cel de antrenare prezintă o distribuție dezechilibrată a datelor. În majoritatea cazurilor, numărul pacienților sănătoși domină atât setul de antrenare, cât și setul de testare, motiv pentru care chiar și pentru situația în care modelul supraînvață caracteristicile unei clase dominante, acuratețea va indica o valoare optimă.

Analiza Matricei de Confuzie

Pentru a evalua modul în care modelul reușește să clasifice etapele retinopatiei, este esențială analiza matriciei de confuzie în cadrul problemelor de clasificare [35]. Aceasta este o matrice pătratică, rândurile indică clasa reală a fiecărei imagini fundoscopice, iar coloanele indică predicțiile prezise de model. Un exemplu vizual poate fi consultat în figura 3.24. Pe baza matricii de confuzie, pentru fiecare din cele 5 clase se pot extrage 4 metrici esențiale ce sunt vizibile în tabelul 3.1, precum numărul de pacienți fals-pozitivi(FP), fals-negativi(FN), adevărați pozitivi(TP) respectiv adevărați negativi(TN).

Adevărați Pozitivi (TP)	Fals Pozitiv (FP)
Fals Negativ (FN)	Adevărat Negativ (TN)

Tabelul 3.1. Matricea de confuzie aferentă unei clase

Pentru orice problemă de clasificare, idealul este să se poată obține o matrice de clasificare pentru care cât mai mulți pacienți să fie clasificați pe diagonala principală a acesteia. Cazul cel mai nefavorabil ce se dorește a fi evitat cât mai mult în aplicațiile medicale este nedetectarea pacienților bolnavi, care ulterior vor fi clasificați ca fals negativi.




Figura 3.24. Matrice de confuzie

Pe baza celor 4 metrici extrase pentru fiecare clasă, se vor calcula Precizia, Reamintirea și scorul F1 [20].

Metrici Derivate: Precizia, Reamintirea și Scorul F1

Precizia reprezintă numărul de cazuri identificate corect din numărul total al cazurilor identificate [20]. Această metrică se măsoară cu ajutorul formulei:

$$P = \frac{TP}{TP + FP}$$

Reamintirea este definită ca numărul de cazuri identificate corect din numărul total al eșantioanelor ce aparțin claselor respective [20]. Se poate măsura cu formula:

$$R = \frac{TP}{TP + FN}$$

Pentru a evalua corect modelul, este absolut necesară monitorizarea simultană a celor 2 metrici. Pentru aceasta, se va evalua o nouă metrică cunoscută drept scor F1 [20], ce reprezintă media armonică dintre precizie și reamintire, pe baza formulei:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Pentru a obține un scor F1 cât mai bun, este necesar ca ambele măsurători să indice valori cât mai bune.

Evaluarea Globală a Claselor: Macro-Averaging și Micro-Averaging

Calitatea clasificării globale se poate măsura utilizând Macro-averaging, respectiv Micro-averaging [36]. Macro-averaging tratează toate clasele în mod egal. Nu se ține cont de distribuția eșantioanelor din setul de test. Micro-averaging în schimb acordă ponderi diferite în funcție de numărul de eșantioane asociat fiecărei clase [36].

Coeficientul Quadratic Weighted Kappa(QWK)

O metrică des utilizată ce evaluează modelele din cadrul competițiilor disputate pe platforma Kaggle reprezintă Quadratic Weight Kappa [37]. Acest coeficient se bazează pe valorile a 3 matrici distincte, matricea de confuzie, matricea de ponderi, respectiv matricea de așteptări [37].

Matricea de confuzie U indică câte eșantioane din clasa reală i , au fost prezise în clasa j [37]. Relația ce modelează elementele din matrice este:

$$U=(u_{i,j})$$
$$u_{i,j} = \sum_{k=1}^n \mathbb{I}(a_k = i) \cdot \mathbb{I}(b_k = j)$$

a – Etichete reale

b – predicțiile modelului

n - numărul de elemente ale matricii

Matricea de așteptări V se calculează sub forma produsului distribuțiilor marginale, normalizate la numărul de elemente n [37].

$$V = \frac{(U \cdot e) \otimes (U^T \cdot e)}{n}$$

U – matricea de confuzie

n – numărul de elemente ale matricii de așteptări

Matricea ponderilor W penalizează erorile în mod proporțional cu pătratul distanței între cele 2 note [37].

$W=(w_{i,j})$, unde

$$w_{i,j} = \frac{(i - j)^2}{(l - 1)^2}$$

Pe baza celor 3 matrici, indicele QWK se poate măsura utilizând formula [37]:

$$\kappa(a, b) = 1 - \frac{\sum_{i,j=1}^l u_{i,j} \cdot w_{i,j}}{\sum_{i,j=1}^l v_{i,j} \cdot w_{i,j}} = 1 - \frac{\langle U, W \rangle_F}{\langle V, W \rangle_F}$$

Scorul QWK poate lua valori cuprinse în intervalul $[-1,1]$. Un scor negativ denotă faptul că predicțiile sunt mai slabe decât o ghicire în mod complet aleatoare, în timp ce un scor cât mai apropiat de 1 reliefează un model ce poate face predicții cu o exactitate precisă [37].

Interpretând clinic coeficientul Kappa, literatura medicală definește următoarele praguri între predicții și stadiile reale [38]:


- Sub 0.00 – Concordanță slabă
- 0.00 - 0.20 – Concordanță ușoară
- 0.21 - 0.40 – Concordanță acceptabilă
- 0.41 - 0.60 – Concordanță moderată
- 0.61 - 0.80 – Concordanță substanțială
- 0.81 – 1 – Concordanță aproape perfectă

3.7. Explicabilitatea deciziilor folosind algoritmul Grad-CAM

Pentru validarea arhitecturii propuse, a fost integrat algoritmul Grad-CAM (Gradient-weighted Class Activation Mapping) [39]. Această tehnică permite generarea unei hărți termice de localizare (heatmap) care evidențiază regiunile spațiale din imaginea fundoscopică ce au contribuit cel mai mult la decizia finală a rețelei neuronale.

Din punct de vedere matematic, Grad-CAM utilizează informațiile de gradient care se propagă înapoi (backpropagation) către ultimul strat convoluțional al rețelei. În cazul modelului EfficientNet-B3 utilizat în această lucrare, s-a vizat stratul `top_conv`. Acest strat a fost ales deoarece reprezintă compromisul ideal: este suficient de adânc pentru a extrage caracteristici semantice complexe (cum ar fi prezența microanevrismelor sau a exsudatelor), dar, păstrându-și natura convoluțională, conservă cu precizie informațiile spațiale care s-ar pierde după aplicarea stratului de mediere globală (Global Average Pooling).

În contextul modelului de regresie ordinală implementat, algoritmul a fost adaptat pentru a calcula gradientii în raport cu suma probabilităților celor patru neuroni decizionali (scorul global de severitate). Harta de activare rezultată este redimensionată la dimensiunile imaginii de intrare și suprapusă peste aceasta.



Grad-CAM (Zonele de atenție ale rețelei)

Figura 3.25. Validarea deciziei modelului folosind Grad-CAM

Așa cum se observă în Figura 3.25, zonele evidențiate prin culori calde (roșu, galben) indică regiunile de maxim interes pentru algoritm, confirmând faptul că rețeaua se concentrează pe regiunile anatomice relevante clinic (ex. discul optic, macula) și pe zonele cu anomalii vasculare. Zonele reprezentate cu albastru închis indică regiunile din fundal (inclusiv masca aplicată în etapa de pre-procesare), demonstrând că modelul ignoră zgomotul și nu se bazează pe artefacte pentru a clasifica stadiul retinopatiei diabetice.

Capitolul 4: Rezultate Experimentale

4.1 Setul de date utilizat

Setul de date a fost colectat în urma desfășurării a două concursuri organizate pe platforma online Kaggle, Diabetic Retinopathy Detection [40] în anul 2015, respectiv APTOS Blindness Detection [3] în anul 2019.

În cadrul competiției Diabetic Retinopathy Detection, baza de date pe care au avut-o la dispoziție concurenții conține în total 35126 imagini fundoscopice puse la dispoziție pentru etapa de antrenare, furnizate de către platforma specializată de telemedicină EyePACS [40]. În urma finalizării competiției, setul de test a fost făcut public, acesta având în componența sa 53576 de fotografii. Imaginile au fost realizate sub diverse condiții, astfel încât claritatea imaginilor diferă semnificativ. Pentru fiecare pacient au fost realizate fotografii atât pentru globul ocular stâng, cât și pentru cel drept [40].

Imaginile au fost realizate cu diverse aparaturi și tipuri de camere. Pozele pot fi prezentate sub influența a diferitelor tipuri de zgomot, pot fi nefocalizate, supraexpuse sau subexpuse [40].

Concurenții competiției APTOS 2019 Blindness Detection au avut la dispoziție un set de 3662 de imagini fundoscopice furnizate de către clinica Aravind Eye Hospital [3]. Scopul acestui concurs a fost dezvoltarea unui model care să clasifice pe baza setului de fotografii furnizat, severitatea retinopatiei diabetice la nivelul globului ocular, similar celui desfășurat în anul 2015. Cea mai bună soluție a fost prezentată în cadrul celui de-al patrulea Simpozion al Societății Asia-Pacific de Tele-Oftalmologie(APTOS). Tehnicienii oftalmologi pentru a achiziționa setul de imagini au vizitat comunitățile rurale din India pentru a realiza fotografii fundoscopice [3], iar ulterior medicii au etichetat fiecare fotografie, asignând diagnosticul specific fiecărei retine observate.

Directorul ce conține în componența sa setul de fotografii pentru antrenare prezintă un număr de 38788 de fotografii fundoscopice. În același fișier de antrenare au fost reunite atât pozele puse la dispoziție în cadrul competiției Diabetic Retinopathy Detection, cât și cele oferite cu ocazia concursului Aptos 2019. Scopul pentru care au fost selectate mai multe imagini din cadrul mai multor competiții este de a obține un model robust, capabil să învețe aspectele de bază(forma și aspectul maculei, forma capilarelor nervoase, vascularizarea), ignorând datele de natură zgomotoasă. Fiecărei fotografii îi corespunde una dintre cele cinci etichete ce reprezintă diferite etape ale afecțiunii: 0-No_DR, 1 - Mild, 2 – Moderate, 3 – Severe, 4 – Proliferative_DR [3].

Eticheta 0-No DR(Diabetic Retinopathy) este specifică pacienților ce suferă de diabet zaharat care nu prezintă simptome ale bolii. Un exemplu din această clasă poate fi identificat în figura 4.1.




Figura 4.1. Fotografie specifică clasei 0_No_Diabetic_Retinopathy. Sursa [3]

Eticheta 1-Mild reliefează debutul afecțiunii la nivelul globului ocular. O imagine ce indică o retină de acest tip poate fi identificată în figura 4.2.



Figura 4.2. Fotografie specifică clasei 1_Mild. Sursa [3]

În cazul etichetei 2-Moderate, o fotografie tipică poate fi vizualizată în figura 4.3. Se observă prezența microanevrismelor care de această dată sunt mai numeroase, de dimensiuni mai mari față de cazul precedent.




Figura 4.3. Fotografie specifică clasei 2_Moderate. Sursa [3]

În etapa a 3-a a afecțiunii, careia îi este asociată eticheta 3-Severe, vasele de sânge se vor ramifica anormal, acest fapt fiind vizibil în figura 4.4, remarcându-se o vascularizare anormală a capilarelor.




Figura 4.4. Fotografie specifică clasei 3_Severe. Sursa [3]

Ultimul stadiu al afecțiunii este identificat cu eticheta 4-Proliferative_DR(Diabetic Retinopathy). O fotografie fundoscopică specifică acestui stadiu poate fi văzută în figura 4.5 . Retina nu mai are acces la oxigen, iar suprafața nervului optic este vizibilă o puternică vascularizare.



Figura 4.5. Fotografie specifică clasei 4_Proliferative.
Sursa [3]

Pe baza directorului ce are în componența sa datele de antrenare, în figura 4.6 s-a realizat graficul funcției de distribuție a eșantioanelor în funcție de clasa specifică. Se observă o distribuție dezechilibrată a fotografiilor retinopatie. Cele mai multe fotografii sunt corespunzătoare unor retine sănătoase, în număr de 27615. Se reliefează un număr semnificativ de fotografii ce corespund clasei Moderate, în număr de 6291. Fotografiile care indică un stadiu incipient al bolii și cele care indică etapa severă sunt numeric mai reduse comparativ cu clasele precedente, înregistrând 2813 de exemple cu eticheta 1_Mild, respectiv 1066 din categoria Severe. Din categoria datelor ce indică un stadiu proliferativ se numără cele mai puține fotografii, doar 1003. Distribuția neuniformă a datelor de antrenare va constitui un principal dezavantaj în cadrul procesului de antrenare al modelului.




Figura 4.6. Histograma distribuției imaginilor

4.2. Rezultate Experimentale

4.2.1. Experimente bazate pe arhitectura ResNet50

Experiment 1: Antrenarea de bază

În prima etapă, așa cum am menționat în capitolul dedicat setului de date achiziționat, am reliefat faptul că distribuția claselor nu respectă o lege uniformă. Din acest motiv, am realizat o subeșantionare a claselor. Am selectat în mod aleatoriu 1000 de fotografii pentru fiecare clasă. În total se vor utiliza 5000 de imagini fundoscopice pentru a antrena modelul, astfel încât rețeaua să poată identifica un număr egal de eșantioane din fiecare clasă, fără să supraînvețe anumite caracteristici specifice unor clase cu un număr semnificativ mai mare de elemente.

Am realizat gruparea imaginilor în loturi a câte 32. Conform studiilor de specialitate întreprinse de către cercetătorului Yoshua Bengio [26], alegerea implicită a unui lot de dimensiune 32 reprezintă o valoare de start potrivită.

Am citit datele din directoarele salvate local în cadrul platformei Kaggle. Întrucât structura fișierelor se poate modifica, se va căuta un document de referință, în cazul de față `train.csv`, în cadrul căruia se va salva folderul în variabila `BASE_DIR`. Am mai declarat 2 variabile aferente loturilor de antrenare și de testare, denumite `TRAIN_DIR`, respectiv `TEST_DIR`. Așa cum am menționat anterior, asupra setului de antrenare am aplicat un procedeu de subeșantionare pentru a selecta 1000 de fotografii per clasă, iar în cazul în care o clasă prezintă mai puține eșantioane, se va selecta întregul set din directorul aferent clasei respective. În ceea ce privește datele de testare, am selectat în întregime totalitatea eșantioanelor existente în lotul de test, pentru a demonstra robustețea modelului. Noua distribuție a datelor de antrenare este reprezentată în figura 4.7.




Figura 4.7. Histograma datelor de antrenare, în urma subeșantionării lotului de antrenare

Pentru a urmări etapa de antrenare și pentru a măsura metricile de acuratețe și de eroare, am împărțit întregul set dedicat antrenării în două loturi specifice antrenării și validării, conform regulii

80-20 pentru fiecare dintre cele 5 clase distincte, însă această divizare nu s-a aplicat pe întreg setul de imagini, ci pentru pacienți. În setul de date furnizat de către clinica EyePacs, se regăsesc fotografii ai ambilor ochi în cadrul unor pacienți. Poate apărea situația în care în cadrul unui pacient, un ochi poate aparține setului de antrenare, iar perechea sa lotului de validare. Utilizând această regulă, se evită complet situația în care rețeaua procesează o anumită imagine a unui pacient, pe care ulterior o poate recunoaște când se dorește evaluarea antrenării. În cazul setului de date Aptos, fiecare fotografie este tratată ca aparținând fiecărui pacient diferit. Pe baza acestei reguli, setul de validare va indica la ce performanțe ajunge modelul în cazul unor date neîntâlnite, în același timp va detecta capacitatea de generalizare a modelului evaluat.

Arhitectura utilizată pentru antrenare este ResNet50, fiind una dintre cele mai populare arhitecturi utilizate pentru a rezolva probleme de natură medicală [20]. La bază voi utiliza conceptul de Transfer Learning pentru a rezolva o problemă de natură medicală, în așa fel încât voi utiliza o arhitectură preantrenată pe setul de date Imagenet. La ieșirea rețelei se va aplica un strat adițional denumit GlobalAveragePooling2D, ce realizează operația de mediere la nivelul fiecărei hărți generate la ieșirea rețelei, cu scopul de a preveni fenomenul de supraînvățare, numărul de parametri fiind redus semnificativ. Ulterior, am aplicat o regularizare de tip Dropout pentru a anula aleator 50% din numărul total de neuroni în procesul de învățare. La ieșirea rețelei am înlocuit capul nativ de clasificare al rețelei ResNet50 care era menit să execute clasificarea a 1000 de obiecte distincte, cu un cap de clasificare multiclasă pentru cele 5 etape ale retinopatiei diabetice pe care modelul trebuie să le clasifice corespunzător. Implicit, funcția de activare utilizată la ieșire este softmax, selectându-se cel mai bun scor înregistrat pentru apartenența imaginii la fiecare clasă. Vizual, poate fi consultată figura 4.8.



Figura 4.8. Arhitectura utilizată

În ceea ce privește etapa de antrenare, am realizat procesul de fine-tuning progresiv în 5 etape succesive.

În prima etapă, am păstrat întreaga rețea înghețată, antrenând exclusiv doar capul de clasificare al rețelei. Procesul de antrenare al ponderilor aferente stratului complet conectat al ieșirii rețelei ResNet50 se va efectua utilizând optimizatorul Adam. Acesta e frecvent utilizat în diverse aplicații medicale, înregistrând rezultate semnificativ superioare comparativ cu alte funcții de optimizare. În ceea ce privește alegerea ratei de învățare, pentru fiecare etapă individuală de dezghețare a rețelei, am selectat câte o rată distinctă, specifică ponderilor fiecărui bloc convoluțional ce alcătuiește modelul ResNet50. Pentru ieșirea rețelei am selectat în mod pur experimental o rată de învățare de ordinul 10^{-3} , rulând algoritmul pentru un număr de 7 epoci. Mai apoi, am dezghețat întreaga structură conv5 aflată la ieșirea rețelei, iar pentru a menține stabile ponderile preantrenate, am redus rata de învățare cu 2 ordine de mărime, la valoarea 10^{-5} . Ca și funcție de cost pentru a penaliza rezultatele eronate obținute de către model este funcția de cost entropie încrucișată, fiind standard pentru probleme de clasificare. Reliefându-se faptul că distribuția claselor respectă o lege uniformă, nu a fost necesară aplicarea unor ponderi suplimentare.

Pentru a evita fenomenul de supraînvățare ce poate fi cauzat de faptul că pentru un număr de doar 5000 de poze am utilizat o rețea de clasificare ce prezintă în componența sa 20 de milioane de parametrii, am aplicat tehnica de regularizare Early Stopping, ce va contoriza activitatea funcției de pierderi pe parcursul procesului de antrenare. În situația în care pentru 5 epoci consecutive nu are loc o scădere a funcției de eroare, procesul de antrenare va fi oprit în mod forțat, salvându-se ponderile aferente modelului pentru care s-au înregistrat valori minime ale funcției de eroare.

O altă modalitate de regularizare aplicată este ReduceLROnPlateau, ce va reduce rata de învățare la jumătate în cazul în care pentru 2 epoci consecutive funcția de pierderi nu va înregistra un declin față de valorile sale precedente. Limita inferioară până la care am inițializat această divizare este de 10^{-8} , pentru a realiza o convergență sigură a ponderilor din rețea, cu toate că durata către convergență va fi semnificativ mai mare.

Graficele ce măsoară valoarea acurateței, cât și evoluția funcției de eroare pot fi vizualizate în figurile 4.9, respectiv 4.10.

Conform figurii 4.9, este evidentă discrepanța dintre rezultatele obținute pentru setul de testare comparativ cu cel pentru validare, aceasta devenind mult mai conturată la momentul dezghețării capul conv5. Cu toate că acuratețea pentru antrenare confirmă o creștere continuă, rețeaua nu e capabilă să generalizeze ceea ce a învățat, motiv pentru care se înregistrează o saturare în jurul valorii de 45%. Acest fenomen este vizibil și în graficul din figura 4.10, în care funcția de eroare atinge valoarea minimă de 1.26 pentru epoca 8. Din cauza faptului că pentru 5 etape consecutive nu s-a înregistrat nicio valoare sub valoarea minimă înregistrată de 1.26 pentru funcția de eroare, metoda EarlyStopping a intervenit producând o stopare imediată a procesului de antrenare. Este evident faptul că rețeaua a supraînvățat parametrii specifici fotografiilor aflate în fișierul de testare, nereușind să identifice informații cheie din cadrul unui nou set de date furnizat.




Figura 4.9. Evoluția metricii de acuratețe pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul primului experiment




Figura 4.10. Evoluția funcției de pierderi pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul primului experiment

Experiment 2: Suplimentarea lotului de antrenare

Un motiv principal pentru care rezultatele aferente antrenării au fost sub nivelul așteptărilor este insuficiența cantității de date pentru a susține un număr foarte mare de parametrii ai rețelei. Pentru a realiza o antrenare eficientă, am utilizat totalitatea fotografiilor fundoscopice disponibile în setul de date achiziționat al pacienților care se află într-una din etapele „Mild”, „Moderate”, „Severe”, respectiv „Proliferative” ale retinopatiei diabetice. Pentru clasa „Mild” am colectat 2813 fotografii, pentru clasa „Moderate” am selectat 5000 de fotografii, iar pentru clasele „Severe”, respectiv „Proliferative” am extras numărul maxim de poze disponibile, 1066 și 1003 eşantioane. Cu toate că în cazul clasei pacienților sănătoși am la dispoziție un număr de 27615 fotografii, voi utiliza 5000 de fotografii alese în mod aleator, pe de o parte pentru a evita situația cu care m-am confruntat în cazul precedent în care rețeaua a supraînvățat particularitățile specifice pacienților sănătoși, iar pe de altă parte ar fi necesară aplicarea unor ponderi foarte agresive claselor întâlnite mai rar pentru a compensa numărul imens al pacienților considerați sănătoși, în raport cu clasele mai rare al pacienților bolnavi. Astfel, selectând 5000 de poze al pacienților ce nu prezintă nicio afecțiune oculară, raportul dintre clase va fi aproximativ 5:3:5:1:1, fiind rezonabil pentru o funcție de cost să penalizeze suficient de mult eşantioanele ce aparțin unor clase mai rare decât celelalte, pentru a compensa inegalitatea setului de date. Histograma care indică noua distribuție a setului de antrenare este vizibilă în figura 4.11.




Figura 4.11. Histograma datelor de antrenare, în urma adăugării de noi eșantioane în lot.

Din acest motiv, am realizat trecerea de la funcția de cost de tip entropie încrucișată la o metodă adaptată cunoscută drept Focal Loss. Am definit parametrul γ la valoarea 2, standard în literatura de specialitate, această valoare fiind la limita dintre a crea o funcție de cost prea restrictivă sau prea relaxată (în situația în care valoarea lui γ este 1, funcția Focal Loss devine entropie încrucișată). Am păstrat ca și în etapa precedentă același număr de epoci pentru care voi dezgheța progresiv fiecare bloc convoluțional al rețelei ResNet50, rulând cu aceleași rate de învățare și utilizând în continuare optimizatorul Adam. Rezultatele ce înglobează evoluția metricii de acuratețe, cât și a funcției de pierderi pot fi identificate în figurile 4.12 și 4.13.




Figura 4.12 Evoluția metricii de acuratețe pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul celui de-al doilea experiment




Figura 4.13. Evoluția metricii de eroare pentru datele de antrenare și pentru datele de validare, ulterior dezghețării blocului conv5, în cadrul celui de-al doilea experiment

Cu toate că am furnizat lotul de antrenare cu mai multe date pentru a susține procesul de antrenare, nu am rezolvat problema supraînvățării. Discrepanța dintre rezultatele pentru seturile de antrenare și validare sunt în continuare vizibile. Asemeni cazului anterior, diferența dintre cele 2 funcții devine din ce în ce mai evidentă după dezghețarea blocului conv5. Din cauza faptului că funcția de pierderi atinge valoarea minimă în cadrul epocii 9, după care semnalează o saturație timp de 5 epoci consecutive, tehnica EarlyStopping oprește antrenarea cu o epocă înainte de a ajunge la cele 8 epoci programate pentru a antrena blocul conv5.

Cu toate că am furnizat mai multe fotografii fișierului de antrenare, performanțele obținute nu s-au îmbunătățit. În continuare, rețeaua nu este capabilă să generalizeze informațiile captate. În următoarea fază, am analizat fotografiile fundoscopice și am constatat faptul că acestea prezintă un nivel ridicat de zgomot tehnic. Din cauza faptului că fotografiile efectuate provin din mai multe centre medicale, acestea au fost realizate sub diferite pretexte, precum utilizarea unor camere de fotografiat diferite, iluminări diferite ale pozelor, fundalul negru din jurul ochilor fiind inconstant al iluminării, rețeaua ajunge în situația în care memorează aspecte specifice fiecărei poze, în loc de a memora patologii specifice retinopatiei. Din această cauză, am aplicat o serie de pre-procesări la nivelul tuturor imaginilor din setul de antrenare și de test.

Experiment 3: Pre-procesarea CLAHE

Într-o primă etapă, am redimensionat imaginile de la dimensiunea lor inițială de 224×224 pixeli la 512×512 , pentru a spori detaliile semnificative precum aspectul anumitor microanevrisme cât și a diverselor puncte ce pot indica existența retinopatiei la nivelul globului ocular. Pentru a nu

genera eventuale probleme legate de capacitatea maximă a memoriei de lucru RAM, am redus parametrul batch-size de la valoarea 32 la valoarea 16.

Ca și primă etapă de pre-procesare, am aplicat o metodă de decupare a zonei de interes. Am convertit imaginea în format gri și am realizat o segmentare cu un prag situat la valoarea 10. Astfel, pixelii ce au o valoare deasupra pragului vor deveni complet albi, restul rămânând la nivelul negru, pentru a separa fundul optic de fundal. Mai apoi, se va calcula și selecta cel mai mare contur, pentru a centra globul ocular și a elimina marginile negre inutile.

În pasul următor, am redimensionat imaginea la 512×512 pixeli, după care am generat o matrice cu valori nule, iar în centru am inițializat un cerc corespunzând formei globului ocular, pentru care am generat valori de 255 (corespunzător culorii alb). Aplicând operația bitwise_and între pixelii imaginii redimensionate și matricea generată, se vor păstra doar valorile pixelilor ce corespund structurii ochiului, iar fundalul va fi inițializat cu valoarea 0. Arhitectura se va concentra exclusiv asupra zonei anatomice, și va ignora complet zonele de fundal.

În continuare ne confruntăm cu situația în care unele imagini sunt fie sub-expuse, fie supraexpuse. În alte situații, anumite zone ale imaginii sunt expuse vizibil, existând totuși doar anumite zone ce nu sunt suficient de vizibile, pierzându-se astfel din informație utilă. Pentru această situație, am realizat conversia din spațiul standard RGB la spațiul LAB. Canalul L conține informație despre luminanța imaginii, în timp ce componentele A și B conțin informație despre culori. Am aplicat funcția de egalizare a histogrammei CLAHE (Contrast Limited Adaptive Histogram Equalization) strict pentru canalul L. Am convertit imaginea înapoi la spațiul RGB, pentru a obține imaginea originală.

Față de etapa precedentă, am păstrat aceeași structură a rețelei neuronale, cât și aceleași tehnici de regularizare. Am păstrat aceeași abordare de a efectua Fine Tuning progresiv. Am antrenat timp de 7 epoci capul de clasificare inițializând rata de învățare cu valoarea 10^{-3} , ulterior dezghețând întreg blocul conv5 pe care l-am antrenat timp de 8 epoci suplimentare cu o rată de învățare cu 2 ordine de mărime mai redusă, am obținut o dinamică de învățare ce poate fi vizualizată în figura 4.14.




Figura 4.14. Evoluția metricii de acuratețe după 15 epoci, în urma efectuării pre-procesărilor asupra lotului de date

Cu toate că am efectuat o serie de pre-procesări pentru a obține imagini de o calitate superioară, în continuare nu am rezolvat problema supraînvățării. Modelul nu reușește nici de această dată să generalizeze informația pe care o extrage.

Experiment 4: Pre-procesarea Ben Graham

După ce am efectuat o serie de căutări pentru a identifica ce pre-procesare este cea mai potrivită pentru setul de date pe care îl utilizez, am descoperit faptul că în cadrul competiției disputate în anul 2015 pe platforma Kaggle, câștigătorul competiției a aplicat o pre-procesare ce îi poartă numele, bazată pe substrația mediei locale, cunoscută drept normalizare Ben Graham.

Această funcție izolează canalul verde din spațiul RGB, oferind un contrast maxim între rețeaua capilarelor, microanevrisme și fundalul roșu al retinei. Pentru imaginea generată, se va aplica un filtru de tip gaussian proporțional cu dimensiunea imaginii. Astfel, se va face diferența dintre pixelul imaginii originale și cel mediat, pentru care se va aduna o constantă de 128 pentru a centra distribuția pixelilor la un nivel de gri mediu.

În ceea ce privește etapa pre-procesărilor, din cauza adăugării valorii constante de 128 prezente în zonele uniforme, fundalul imaginii primește informație redundantă pe care rețeaua o poate interpreta ca fiind utilă în detecția anomaliilor prezente în cazul retinopatiei. Este esențial ca masca să fie aplicată la ultimul pas, pentru a ignora complet fundalul imaginii și a păstra doar informația specifică de la nivelul ochiului.

În cadrul etapei de dezghețare, am utilizat o rată de învățare mai fină în cazul dezghețării blocului conv5. Pentru antrenarea capului de clasificare, am mărit numărul de epoci de la 7 la 10, întrucât aceasta are nevoie de mai multe epoci pentru a-și stabiliza ponderile, care în primă etapă sunt inițializate în mod aleator, spre deosebire de ponderile aferente rețelei ResNet50 ce sunt pre-antrenate. Pentru dezghețarea blocului conv5, am utilizat o rată de învățare de 5×10^{-6} , mai redusă față de etapa anterioară, când m-am confruntat cu situația în care modelul nu a reușit să își actualizeze ponderile corespunzător pentru a clasifica corect etapele retinopatiei pentru eșantioanele neîntâlnite situate în lotul de validare.

În graficul aferent figurii 4.15, se poate constata faptul că aplicarea unei metode de pre-procesare ce înglobează mai multă informație despre aspectul și forma nervurilor și a capilarelor în schimbul informației de culoare indică în continuare faptul că ponderile sunt capabile să rețină cu o acuratețe excelentă toate detaliile semnificative din cadrul imaginilor reprezentate în urma etapelor de pre-procesare, însă în continuare rețeaua nu clasifică eficient imagini neîntâlnite.




Figura 4.15. Evoluția metricii de acuratețe după 18 epoci, în urma efectuării pre-procesării Ben Graham

Experiment 5: Augmentarea lotului de antrenare

Cu toate că am aplicat o serie de pre-procesări indispensabile ce rezolvă problema iluminării neuniforme și evidențierea de contururi și detalii fine, nu am reușit să rezolv o problemă fundamentală ce reprezintă o limitare a rețelelor neuronale, și anume memorarea efectivă a pozițiilor pixelilor. Astfel, aplicând numeroase tehnici de pre-procesare, acestea nu s-au dovedit a fi suficiente, motiv pentru care în următoarele etape voi aplica o serie de algoritmi de augmentare a datelor strict pentru lotul de antrenare.

În prima etapă, am realizat oglindirea a 50% din imaginile setului extras exclusiv pentru antrenarea rețelei. Ulterior am aplicat o rotație aleatoare a imaginilor originale cu un unghi din intervalul $[-360^\circ, 360^\circ]$. Totodată, am scalat imaginea cu un factor care variază uniform cu o proporție de $\pm 10\%$.

În urma aplicării algoritmilor de augmentare asupra lotului de antrenare, în etapa de antrenare am dezghețat progresiv blocurile superioare ale rețelei ResNet50. M-am oprit la blocul convoluțional conv2, pentru care ponderile aferente au fost antrenate să detecteze detalii grosiere la nivelul imaginilor, în așa fel încât dezghețarea acestora ar fi destabilizat procesul de antrenare. Ca și în cazul experimentului precedent, am antrenat în primă fază exclusiv capul de clasificare timp de 10 epoci, ulterior am dezghețat progresiv blocul conv5 pe care l-am antrenat timp de 8 epoci, utilizând o rată de învățare la valoarea 10^{-5} . Dezghețarea blocului conv4 a fost realizată în 2 etape distincte succesive, spre deosebire de structura conv5 ce are în componența sa 3 blocuri convoluționale, aceasta prezintă 6 blocuri, iar dezghețarea bruscă a tuturor ar putea destabiliza procesul de actualizare al ponderilor. Astfel, cele 3 blocuri superioare vor fi antrenate timp de 8 epoci, utilizând o rată de învățare mai redusă, de valoare $5 \cdot 10^{-6}$, iar pentru cele 3 blocuri inferioare, am păstrat același număr de epoci, însă am variat rata de învățare la 10^{-6} . Reducerea ratei de învățare pe măsură ce dezghețăm o rețea cât mai în profunzime este esențială, pentru a evita fenomenul de catastrophic forgetting.

Rezultatele evoluției procesului de antrenare pot fi vizualizate în graficele aferente figurilor 4.16, respectiv 4.17.




Figura 4.16. Evoluția metricii de acuratețe, în urma aplicării augmentărilor geometrice

În urma aplicării augmentărilor, am rezolvat parțial problema supraînvățării. Am descoperit faptul că rețeaua avea tendința să rețină poziția fiecărui pixel aflat în imaginea inițială. Cu toate acestea, se remarcă faptul că în momentul dezghețării blocului conv4, diferența dintre funcția ce înglobează rezultatele antrenării și cea ce indică funcția de validare devine din ce în ce mai accentuată pe trece fiecare epocă.

Analizând figura 4.17, se constată faptul că cele 2 funcții descresc progresiv pe parcursul etapelor de dezghețare, accentuând o convergență stabilă al algoritmului de optimizare. Astfel, rețeaua reușește să diferențieze cu o precizie din ce în ce mai mare stadiile în care se situează pacienții. Convergența celor 2 funcții diferă la nivel de câteva sutimi, în special pentru epocile în care am dezghețat ponderi aferente straturilor din blocul conv4. Astfel, pentru setul de validare, se ating valori minime în jurul valorii de 0.5, după care se remarcă o saturație în jurul acesteia. Pentru lotul de antrenare, valoarea pentru care funcția ajunge la saturație este cu câteva zecimale mai redusă, indicându-se faptul că și în cazul analizei celor două funcții de pierderi, se poate constata o ușoară supraînvățare.




Figura 4.17. Evoluția funcției de eroare, în urma aplicării augmentărilor geometrice

Motivul principal pentru care pentru etapele de fine-tuning ale blocului conv4 se remarcă o ușoară discrepanță dintre lotul de antrenare și de test este cauzat de faptul că rețeaua deblochează un număr semnificativ mai mare de ponderi antrenabile, sporindu-și capacitatea de învățare. Astfel, ponderile se vor actualiza într-un mod în care vor putea reține suficientă informație legată de zgomotul setului de antrenament. Pentru a combate acest fenomen, voi introduce adățional un nou set de augmentări și regularizări.

Experiment 6: Augmentări suplimentare aplicate asupra lotului de antrenare, utilizarea unei rate de antrenare variabile

Augmentările geometrice s-au dovedit necesare, însă în urma experimentelor efectuate acestea au fost insuficiente. Astfel, am introdus o serie de augmentări adăionale, menite să modifice sugestiv uniformitatea imaginilor fundoscopice. Biblioteca Albumenations conține o serie de funcții de augmentare robuste, aplicate dinamic asupra eșantioanelor de antrenare, pentru a spori capacitatea de generalizare și memorare a modelului a datelor noi întâlnite. Am păstrat augmentările geometrice precedente, care includ variația poziției geometrice a artefactelor retiniene. Ceea ce a fost adățional adăugat, constituie implementarea unei tehnici de Cutout reprezentat de funcția CoarseDropout. Pentru jumătate din fotografii se vor plasa în mod aleator maxim 2 elemente complet negre de forma dreptunghiulară peste imagine. Se evită situația în care rețeaua va asocia un diagnostic pe baza unei anumite leziuni extrase, fiind astfel forțată să identifice mai multe indicii sugestive pentru a putea diagnostica în mod corect stadiul retinopatiei.

Cu o probabilitate de 30%, se va aplica un zgomot aditiv Gaussian peste imaginile pre-procesate. Algoritmul Ben Graham la nivel fundoscopic a generat un zgomot de înaltă frecvență, sub forma unor granulații minuscule, pe care modelul îl poate reține în procesul de antrenare. Când se va realiza fine-tuning asupra ponderilor aflate în adâncimea rețelei, modelul nu se va mai concentra peste zgomotul din fundal.

În urma uniformizării componente de luminanță, asignând zonelor uniforme valoarea 128, am aplicat o metodă specifică variației fotometrice, pentru a împiedica memorarea acestei valori. Astfel, rețeaua va fi nevoită să evalueze imaginea la nivelul artefactelor prezente la imagine.

În experimentul precedent, convergența datelor pentru lotul de validare se realiza într-o manieră zgomotoasă. Prin urmare, am utilizat o rată de învățare variabilă pentru fiecare epocă de antrenare, utilizând funcția Cosine Warmup.

Ca și funcție de eroare am păstrat funcția Focal Loss, însă adițional am utilizat o tehnică de regularizare a etichetelor, inițializând un parametru specific cunoscut drept `label_smoothing` la valoarea 0.1.

Procedeul de fine-tuning al rețelei ResNet50 s-a desfășurat pe parcursul a 5 etape consecutive, fiecare etapă derulându-se timp de 10 epoci, debutând cu capul de clasificare atașat la ieșirea rețelei ResNet, pentru care am utilizat o rată de învățare de valoare 10^{-3} . Ulterior, am dezghețat ponderile aferente blocului conv5, pentru care am redus rata de învățare cu 2 ordine de mărime, la valoarea 10^{-5} . Blocul conv4 a fost dezghețat în 2 etape, din cauza dimensiunii sale de două ori mai mare față de celelalte blocuri aflate în structura rețelei ResNet50. Astfel, jumătatea superioară a fost antrenată cu o rată de 5×10^{-6} , iar jumătatea inferioară cu rata de 10^{-6} . Pentru a nu destabiliza ponderile înghețate aflate în adâncimea rețelei, în ultima etapă de fine tuning ce corespunde dezghețării complete a rețelei până la blocul conv3, am utilizat o rată de învățare și mai redusă, de 5×10^{-7} . Figurile 4.18 și 4.19 confirmă eficacitatea augmentărilor adițional aplicate, cât și a regularizărilor.




Figura 4.18. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning




Figura 4.19. Evoluția metricii de eroare, pe parcursul celor 5 etape de Fine Tuning

Augmentările puternice, cât și regularizările au forțat modelul să se bazeze pe diverse trăsături diferite față de cele pe care acesta se baza inițial în lipsa augmentărilor, fiind un principal motiv pentru care pe lotul de antrenare se observă rezultate mai slabe față de lotul de validare ce a rămas intact, asupra sa aplicându-se doar pre-procesările relatate în etapele anterioare. Analizând figura 4.18, se evidențiază faptul că pe parcursul primelor 3 etape de Fine-Tuning, modelul reușește să își adapteze ponderile pentru a extrage cantitatea maximă de informație posibilă. În etapa a 4-a, aferentă dezghețării ponderilor situate în jumătatea inferioară a blocului conv4, se remarcă faptul că valoarea măsurii de acuratețe atinge o convergență în jurul valorii înregistrate de 60% pe lotul de validare. Vizualizând în paralel graficul din figura 4.19, se confirmă acest fapt, curbele de eroare ale celor două seturi scad simultan până în a 4-a etapă de Fine-Tuning, în care se atinge un platou în vecinătatea valorii de 0.6. Întrucât am inițializat parametrul `label_smoothing` cu valoarea 0.1, am forțat existența unei incertitudini, care împiedică evoluția metricilor de eroare spre o valoare absolută 0. Acest fapt previne ca ponderile antrenabile să rețină informații redundante ale eșantioanelor pentru care se antrenează modelul, ce ar putea conduce spre fenomenul de supraînvățare.

Dezghețarea adițională în etapa a 5-a în întregime a blocului conv3 nu aduce o îmbunătățire semnificativă a valorii acurateței, maximul fiind atins în cadrul etapei a 4-a, de 59,96%. Straturile adânci specifice conv3 au fost antrenate pentru a detecta aspecte geometrice universale, comune atât pentru fotografiile fundoscopice, cât și pentru pozele din setul ImageNet cu care rețeaua a fost preantrenată. Am demonstrat faptul că ponderile aferente blocurilor conv5 și conv4 erau cele care aveau nevoie de o actualizare suplimentară pentru problema specifică clasificării etapelor retinopatiei diabetice.

În figura 4.20 se poate analiza clasificarea efectuată în urma inferenței setului de test. Pe axa orizontală se numără pacienții reali ce aparțin fiecărei clase, iar pe axa verticală este reprezentată predicția modelului pentru fiecare clasă. Se constată un dezechilibru masiv al fotografiilor din lotul de testare, clasa No DR fiind majoritară. Acuratețea globală calculată pe întreg setul de testare nu

poate fi o metrică suficientă și validă pentru a evalua robustețea și capacitatea modelului de a generaliza capacitatea acestuia de clasificare, dat fiind distribuția neuniformă a setului de testare, motiv pentru care în tabelul 4.1 am calculat precizia, reamintirea și scorul F1 pentru fiecare clasă.




Figura 4.20. Matricea de confuzie pentru modelul obținut în urma procesului de Fine Tuning

Global Metrics	QWK: 0.6300	Acc: 0.722		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.876	0.818	0.846	39.533
Mild	0.150	0.198	0.171	3.762
Moderate	0.465	0.596	0.522	7.861
Severe	0.476	0.308	0.374	1.214
Proliferative	0.631	0.440	0.519	1.206

Tabelul 4.1. Valoarea metricilor de măsură pentru experimentul 6

În tabelul 4.1, se constată faptul că rețeaua întâmpină dificultăți pentru clasificarea pacienților aflați în etapa Mild, fapt susținut și de rezultatele obținute de metricile de precizie de 0.15 și reamintire de 0.198. Granița dintre aceste 2 clase este foarte fină, fiind constituită de prezența unui singur microanevrism, ori de o ramificație avansată a unor capilare. Din acest motiv se înregistrează mulți

pacienți fals negativi clasificați eronat în clasa No DR, acest fapt fiind vizibil și pentru pacienții aflați în clasa Moderate. Rezultate sub așteptări se remarcă și pentru clasa Severe, semnalând un scor de precizie de 0.476 și de reamintire de 0.308, rețeaua având tendința de a-i clasifica în clasa Moderate. Câștigătorul competiției organizate pe platforma Kaggle în anul 2015, Ben Graham [9], a obținut un coeficient QWK de aproximativ 0.84. Calculând acest coeficient pentru propriul model obținut, am obținut un coeficient de 0.63, pe baza pragurilor clinice setate de Landis și Koch [38], acest scor indică o concordanță substanțială între predicțiile modelului și diagnosticul real al medicului oftalmolog.

Experiment 7: Utilizarea unei arhitecturi de tip cascadă

Studiind literatura de specialitate [41], o eventuală soluție poate fi reprezentată de efectuarea a două clasificări succesive. Într-o primă etapă, problema va deveni una de natură binară, în care se va detecta dacă pacientul suferă de retinopatie, sau dacă prezintă o retină sănătoasă. În cazul pacienților a căror retină este bolnavă, se va efectua o clasificare adițională în care voi asocia un diagnostic fiecărei fotografii analizate.




Figura 4.21. Implementarea arhitecturii cascade

Pentru implementarea primei rețele de clasificare, am păstrat arhitectura ResNet50, inițial preantrenată pentru setul de date ImageNet. Am utilizat aceleași modalități de augmentare și pre-procesare, cât și aceleași tehnici de regularizare. În cadrul setului de date utilizat, am extras totalitatea fotografiilor aferente pacienților bolnavi, în număr de 11173, iar în cadrul pacienților sănătoși am utilizat 15000 de fotografii. Pentru a oferi o siguranță suplimentară în rândul pacienților cărora afecțiunea este prezentă, am aplicat o ponderare de 1.8 pentru clasa pacienților bolnavi, evitând situația în care un fals-negativ nu ar fi tratat la timp. Ca și funcție de pierderi am utilizat funcția Entropie Încrucișată. Am dezghețat progresiv în mai multe etape blocuri convoluționale situate în cadrul rețelei ResNet50 pe parcursul a 10 epoci, oprind dezghețarea în momentul în care observ că nu se mai înregistrează îmbunătățiri semnificative în rândul metricilor de acuratețe și a funcției de

pierderi. Am păstrat cu exactitate aceleași 5 etape de Fine-Tuning, dezghețând aceleași straturi și utilizând aceleași rate de învățare variate cu ajutorul algoritmului Cosine_Warmup. În cazul în care pentru lotul de validare ponderile nu se actualizează corespunzător pentru a înregistra rezultate mai bune, va interveni tehnica de regularizare EarlyStopping.

Al doilea model este proiectat cu scopul de a clasifica pacienții bolnavi surprinși în cadrul primei etape de clasificare binară. Poate exista posibilitatea pentru care un pacient sănătos să fie declarat fals-pozitiv, motiv pentru care ieșirea rețelei va avea în continuare 5 neuroni pentru clasificare, în scenariul în care un pacient fals detectat ca fiind bolnav să poată fi în continuare clasificat ca fiind sănătos. Am distribuit ca și în etapele precedente 2813 fotografii clasei Mild, 5000 de fotografii clasei Moderate, 1066 clasei Severe respectiv 1003 clasei Proliferative. Adicional, am furnizat 2000 de poze ale pacienților sănătoși, pentru cazul în care exista pacienți fals pozitivi clasificați necorespunzător. Etapele de Fine Tuning, numărul de epoci, ratele de învățare rămân identice, iar ca și funcție de cost am păstrat funcția Focal Loss cu parametrul gamma inițializat cu valoarea 2, cât și label_smoothing de 0.1.

Figura 4.22 ce sintetizează evoluția acurateței clasificatorului binar pentru cele 5 etape de Fine-Tuning indică de această dată faptul că modelul atinge un maxim mai devreme decât clasificările realizate precedent. Rețeaua ResNet reușește să extragă maximul de informație cu câteva epoci mai devreme comparativ cu clasificările multi-clasă efectuate anterior.




Figura 4.22. Evoluția acurateței primului model de clasificare binară, pentru 5 etape succesive de Fine-Tuning

În cazul inferenței setului de test, pentru clasificarea efectuată de către primul model am selectat mai multe praguri de decizie pentru a detecta ce fotografii sunt eligibile pentru o clasificare adițională, scopul primului clasificator fiind maximizarea sensibilității. Am variat acest prag în intervalul $[0.25 \ 0.5]$, cu scopul de a înregistra valoarea pentru care se obțin cele mai bune performanțe. În situația în care chiar și pentru cazul în care există o mică incertitudine legată de sănătatea retinei,

un prag redus va asigura faptul că pacientul va fi clasificat adițional, iar în cazul unui fals pozitiv, pacientul poate fi redirecționat înapoi în clasa specifică pacienților sănătoși.

Pentru fiecare valoare specifică pragului de decizie luată în intervalul $[0.25 \ 0.5]$, am reprezentat metricile de tip macro și weighted pentru precizie, reamintire și scorul F1.




Figura 4.23. Evoluția metricilor de măsură pentru fiecare prag ales, pentru cazul în care fiecare clasă are pondere egală

Figura 4.23, se concretizează faptul că precizia crește pe măsură ce pragul de decizie se apropie de 0.5. Se observă faptul că pe măsură ce valoarea pragului crește, numărul pacienților fals pozitivi va scădea, iar astfel precizia deciziilor pozitive crește. Pe de altă parte, modelul va pierde din sensibilitate pe măsură ce valoarea pragului crește, rețeaua începând să omită pacienți bolnavi pe care îi va declara ulterior sănătoși. Astfel, vom obține un model insensibil. Analizând dreapta măsurii de F1, se remarcă faptul că cel mai bun echilibru pentru care nu vor exista multe alarme false, nici un număr semnificativ al pacienților bolnavi omiși este pentru valorile de 0.45 și 0.5.




Figura 4.24. Evoluția metricilor de măsură pentru fiecare prag ales, pentru cazul în care fiecare rezultatul fiecărei măsurători este proporțională cu numărul de poze din fiecare clasă

Figura 4.24 concentrează aceleași măsurători ca și în etapa precedentă, însă de această dată se ține cont și de numărul real de pacienți din fiecare clasă. Precizia este aproximativ constantă pentru orice valoare a pragului, pentru valoarea pragului de 0.25, precizia pentru clasa 0 este maximă, atingând valoarea de 0.91, însă preciziile pentru clasele bolnave sunt mult mai reduse. Acest proces se compensează pentru fiecare valoare a pragului. Precizia scade progresiv pentru clasa 0, în timp ce pentru clasele ce indică stadii ale retinopatiei, aceasta măsură continuă să crească. În altă ordine de idei, reamintirea este minimă pentru pragul de 0.25, întrucât mulți pacienți sănătoși vor fi clasificați greșit de către al doilea model ce identifică severitatea bolii. Pe măsură ce crește valoarea pragului, în a 2-a etapă vor ajunge mult mai puțini pacienți sănătoși, iar modelul va fi mult mai capabil să identifice în ce etapă se situează fiecare pacient. Deoarece majoritatea datelor de test aparțin clasei 0, se va identifica faptul că reamintirea, cât și scorul F1 vor fi crescătoare până la pragul de 0.5, unde se observă o convergență a celor 3 drepte. Echilibrul ideal în acest caz este identificat pentru valoarea pragului de 0.5, confirmat și de etapa precedentă.

Măsurând Quadratic Weighted Kappa pentru fiecare prag în figura 4.25, maximul este înregistrat pentru pragul de valoare 0.5.




Figura 4.25. QWK în funcție de fiecare prag selectat

Analizând matricea de confuzie din figura 4.26, cât și precizia și reamintirea din tabelul 4.2 pentru fiecare clasă, se constată că modelul încă are limitări în special pentru gradele de severitate Mild și Severe, pentru cele 2 remarcându-se cele mai mici valori de Recall, de 0.19 pentru clasa Mild, respectiv 0.358 pentru Severe. Pentru clasa Mild, există tendința de a clasifica majoritatea pacienților ca fiind sănătoși, fapt care în domeniul medical se dorește a fi evitat sub orice formă. Același lucru se poate remarca și pentru clasa Moderate, o bună parte din pacienți fiind clasificați eronat ca fiind sănătoși. Scorul QWK de 0.659 înregistrează o îmbunătățire semnificativă, ce încadrează în continuare modelul ca existând o concordanță substanțială între rezultatele sale și cele ale medicilor.




Figura 4.26. Matricea de confuzie pentru modelul cascadat, prag de 0.5

Global Metrics	QWK: 0.6590	Acc: 0.756		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.878	0.873	0.876	39.533
Mild	0.190	0.191	0.190	3.762
Moderate	0.502	0.548	0.524	7.861
Severe	0.455	0.358	0.401	1.214
Proliferative	0.573	0.454	0.507	1.206

Tabelul 4.2. Precizie, Reamintire și Scor F1 pentru fiecare din cele 5 clase, pentru pragul de 0.5

Arhitectura în cascadă aduce o serie de beneficii, înregistrându-se rezultate mai bune față de modele anterioare, însă nu rezolvă limitările etapelor precedente.

4.2.2. Experimente bazate pe arhitectura EfficientNet-B3

Experiment 8: Implementarea unui nou pipeline de clasificare

Am utilizat rețeaua ResNet50 în diverse configurații. Am aplicat diverse pre-procesări și augmentări specifice, însă pentru setul de date EyePacs rețeaua în continuare întâmpină dificultăți, în special

pentru clasa Mild. În următoarele experimente am utilizat arhitectura EfficientNet-B3, ce permite scalarea după 3 dimensiuni ale imaginii (lungime, adâncime, rezoluție). Pentru a compara performanțele celor 2 modele, am păstrat aceeași distribuție a lotului de antrenare, pre-procesarea Ben Graham, același set de augmentări, cât și aceeași arhitectură ce poate fi vizualizată în figura 4.27, pentru care am obținut cele mai bune rezultate pentru rețeaua ResNet50.




Figura 4.27. Arhitectura pentru EfficientNet-B3

În etapa de dezghețare a rețelei, am păstrat timp de 10 epoci întreaga rețea EfficientNet preantrenată pe setul de date ImageNet înghețată, pentru a stabili ponderile aferente straturilor de clasificare de la ieșirea rețelei, în primă fază acestea fiind inițializate în mod aleator. Am variat rata de învățare pe baza algoritmului cosine warmup, pentru care în etapele trecute am obținut o antrenare stabilă. Rata de învățare maximă a fost de 10^{-3} , ce a fost atinsă în primele 2 epoci de antrenare.

Am dezghețat progresiv blocul 7 al ieșirii EfficientNet timp de 10 epoci, folosind o rată variabilă ce a atins valoarea maximă de 10^{-5} .

Am dezghețat mai apoi blocul 6 timp de 10 epoci de antrenare cu o rată maximă de 5×10^{-6} .

Procesul de antrenare a continuat cu dezghețarea blocurilor 4 și 5 timp de încă 10 epoci adiționale, rata de învățare atingând maximul în valoarea 10^{-6} .

În ultima etapă de Fine-Tuning, am dezghețat blocurile 2 și 3 pentru 10 epoci, cu o rată și mai fină, variabilă până la valoarea maximă de 5×10^{-7} .

Alegerea unor rate cât mai reduse de învățare vor preveni procesul de catastrophic forgetting, rețeaua trebuie să păstreze în continuare informații legate de aspecte grosiere de la nivelul imaginilor.

Ca și funcție de eroare, am păstrat funcția Focal Loss cu parametrul $\gamma=2$, cât și regularizarea de tip label_smoothing ce a fost inițializată cu valoarea 0.1. Funcția de optimizare folosită rămâne în continuare Adam.

Rezultatele procesului de antrenare pot fi vizualizate în figurile 4.28, respectiv 4.29.




Figura 4.28. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning




Figura 4.29. Evoluția metricii de eroare pe parcursul celor 5 etape de Fine-Tuning

Conform figurilor 4.28, respectiv 4.29, se accentuează faptul că tehnicile de regularizare au fost efective și în situația în care am utilizat o nouă rețea pentru clasificare. Pe parcursul celor 50 de epoci, rețeaua reușește să extragă suficientă informație din setul de antrenare pentru a-și adapta ponderile în mod eficient. În figura 4.28, se observă faptul că în primele epoci de antrenare, ponderile vor fi ajustate eficient în așa fel încât modelul crește progresiv în vecinătatea valorii 0.55 pentru lotul de validare. În ultimele etape de fine-tuning, creșterea se va produce într-o manieră mai lentă, fapt ce denotă că rețeaua a reușit să extragă informațiile de bază. Analizând graficul din figura 4.29, funcția de eroare înregistrează valori reduse, ce se mențin relativ constante pe parcursul tuturor epocilor de antrenare.

Pe baza acestor rezultate, am extras matricea de confuzie în figura 4.30, cât și metricile de măsură în tabelul 4.3.




Figura 4.30. Matricea de confuzie pentru modelul obținut, utilizând arhitectura EfficientNet-B3 și pre-procesarea Ben Graham

Global Metrics	QWK: 0.5396	Acc: 0.695		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.869	0.781	0.823	39.533
Mild	0.129	0.085	0.103	3.762
Moderate	0.369	0.658	0.473	7.861
Severe	0.482	0.292	0.364	1.214
Proliferative	0.595	0.393	0.474	1.206

Tabelul 4.3. Valoarea măsurătorilor de acuratețe, precizie, reamintire, scor F1 și QWK pentru experimentul 8

Cu toate că am utilizat o nouă rețea de clasificare, clasa Mild rămâne în continuare cea pentru care se înregistrează cele mai slabe rezultate. Nu se remarcă o îmbunătățire semnificativă față de situația în care utilizam rețeaua ResNet50. Se remarcă chiar rezultate mai slabe pentru toate metricele de măsură, acuratețea globală a scăzut la 69.5%, iar QWK a scăzut la 0.5396, pe baza scalei Landis et al. [38] fiind în categoria de „concordanță moderată”. Modelul nu reușește să traseze granițele fine între etapele adiacente ale bolii.

Un motiv principal pentru care noua rețea utilizată nu a reușit să ofere randamentul așteptat poate fi reprezentat pe de o parte de utilizarea regularizărilor prea agresive ce s-au dovedit a fi eficiente pentru ResNet50, aceasta fiind o rețea ce are în componența aproape dublu ca și număr de parametrii comparativ cu Efficient-NetB3. Pe de altă parte, blocul Squeeze-and-Excitation [24] ce funcționează ca un mecanism de atenție la nivelul canalelor de culoare, există posibilitatea ca modelul să piardă informație în momentul în care utilizăm pre-procesarea Ben Graham, ce folosește doar canalul verde.

Experiment 9: EfficientNet-B3 însoțit de algoritmul CLAHE de pre-procesare

Pentru următoarea etapă voi păstra dimensiunea lotului și rezoluția, însă voi utiliza ca și pre-procesare egalizarea adaptivă de histogramă CLAHE pentru componenta L aferentă spațiului (L,A,B), după care voi trece înapoi la spațiul de culoare (R,G,B). Am păstrat aceleași augmentări, aceeași arhitectură, cu excepția faptului că am redus proporția stratului de Dropout de la 50% la 30%. Ca și funcție de cost, am păstrat funcția Focal Loss cu $\gamma=2$ și $\text{label_smoothing}=0.1$. Ca și algoritm de optimizare a rămas algoritmul Adam.




Figura 4.31. Noul pipeline de clasificare

În ceea ce privește etapa de antrenare, am păstrat aceleași etape de fine-tuning progresiv, pornind de la stratul aferent capului de clasificare și ajungând până la blocul al 2-lea intern. Diferența majoră a constat în alegerea unor rate de învățare mai mari, pentru a permite ponderilor să se actualizeze eficient. Pentru început, am antrenat exclusiv capul de clasificare timp de 10 epoci cu o rată de învățare ce a fost variată cu ajutorul algoritmului Cosine Warmup, ce a atins valoarea maximă la 10^{-3} . Mai apoi am dezghețat blocul 7 timp de 10 epoci cu rata maximă de învățare la 5×10^{-5} . Următorul bloc a fost blocul 6 timp de încă 10 epoci adiționale, cu rata de învățare 2×10^{-5} , blocurile 4 și 5 pentru încă 10 epoci cu rata 10^{-5} . Pentru ultimele 10 epoci de antrenare, am dezghețat blocurile 2 și 3, și am inițializat rata maximă de învățare la 5×10^{-6} . Am inițializat rate mai mari de învățare și pentru blocurile aflate în interiorul rețelei, pentru ca modelul să se poată adapta mai bine asupra fotografiilor fundoscopice.




Figura 4.32. Evoluția metricii de acuratețe pe parcursul celor 5 etape de Fine-Tuning




Figura 4.33. Evoluția metricii de eroare pe parcursul celor 5 etape de Fine-Tuning

În figura 4.32, se observă faptul că pe parcursul primelor 3 etape de dezghețare, rețeaua a învățat progresiv caracteristici specifice clasificării eficiente a retinopatiei diabetice. Atât metrica de acuratețe, cât și funcția de eroare ce poate fi urmărită în figura 4.33 indică faptul că modelul învață eficient. Regularizările, cât și ajustarea ratei de învățare s-au dovedit a fi efective. Maximul metricii de acuratețe înregistrează un record de aproximativ 0.64, fapt ce dovedește că acest model este cel mai eficient dintre toate experimentele derulate.

În ultima etapă de dezghețare se concretizează o ușoară saturație a acurateței, iar funcția de eroare atinge un platou în jurul valorii 0.6.




Figura 4.34. Matricea de confuzie pentru modelul obținut, utilizând arhitectura EfficientNet-B3 și pre-procesarea CLAHE

Matricea de confuzie confirmă faptul că pentru clasele ce indică o etapă avansată a afecțiunii, modelul reușește să clasifice pacienții afectați. Dificultatea rămâne în continuare clasa Mild, pentru care există în continuare pacienți ce prezintă forme ușoare, însă detectorul îi clasifică ca fiind „sănătoși”.

În tabelul 4.4 se accentuează faptul că s-au obținut cele mai bune scoruri de precizie și reamintire pentru fiecare clasă analizată individual. Acuratețea globală atinge o valoare record de 76.8%. Același lucru se poate spune și despre QWK, ce indică un scor de 0.6856, încadrându-se în categoria de concordanță substanțială, indicând faptul că majoritatea clasificărilor sunt destul de precise, chiar și între clase consecutive. Efectuând acest experiment am obținut cel mai optim model de până acum.

Global Metrics	QWK: 0.6856	Acc: 0.768		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.885	0.873	0.879	39.533
Mild	0.200	0.178	0.189	3.762
Moderate	0.518	0.612	0.561	7.861
Severe	0.482	0.404	0.440	1.214
Proliferative	0.677	0.525	0.591	1.206

Tabelul 4.4. Valoarea metricilor de interes pentru experimentul 9

Cu toate că am obținut rezultate mai bune, în continuare rămân pacienți fals-negativi netratați, în special pentru clasele Mild și Moderate. O bună parte din pacienți sunt clasificați eronat ca fiind „sănătoși”, declarați fals-negativi.

Experiment 10: Implementarea clasificării prin regresie ordinală

În continuare, voi încerca o altă abordare de clasificare, bazată pe regresie ordinală. Pentru stratul final de clasificare în locul celor 5 neuroni aferenți fiecărei clase, voi utiliza 4 neuroni ce vor răspunde progresiv la câte o întrebare legată de intensitatea afecțiunii. Modelul va răspunde la o cascadă de interogări (Spre exemplu, primul neuron va verifica dacă imaginea fundoscopică aparține unui pacient care este cel puțin în stadiul Mild, al doilea neuron va interoga dacă pacientul este cel puțin în stadiul Moderate etc). Pentru a fi posibilă această metodă de clasificare, este necesar ca etichetele inițiale aferente diverselor etape ale retinopatiei să fie modificate corespunzător (Un pacient în stadiul sever va primi eticheta $[1, 1, 1, 0]$ față de cea inițială $[0, 0, 0, 1, 0]$). Pentru ultimul strat al arhitecturii, am utilizat în locul funcției de activare softmax specifică clasificărilor multclasă funcția sigmoid, ce va calcula probabilități între 0 și 1. Fiecare neuron va realiza o clasificare binară.

Pentru acest experiment am păstrat aceleași pre-procesări (CLAHE pe spațiul L din spațiul LAB) și augmentări ca și în cazul anterior pentru care am obținut cele mai bune metrice de măsură. Am realizat fine-tuning în aceeași manieră. Ca și funcție de pierderi am calculat Focal Loss Ordinal. S-a calculat eroarea independent pentru fiecare neuron utilizând funcția de cost Binary Cross-Entropy. Erorile au fost ulterior însumate. Astfel, rețeaua va fi nevoită să respecte ordinea bolii. Pentru a atenua dezechilibrul datelor, parametrul gamma specific funcției Focal Loss a fost inițializat cu valoarea 2, ca și în experimentele anterioare. Ca și optimizator am păstrat funcția Adam.

Graficul pentru evoluția metricii de acuratețe și eroare poate fi consultat în figura 4.35, respectiv 4.36.




Figura 4.35. Evoluția metricii de acuratețe în cazul regresiei ordinale




Figura 4.36. Evoluția funcției de eroare

Figura 4.35 indică o creștere accelerată a acurateței încă din prima etapă a antrenării stratului de clasificare. Cu toate că acuratețea atinge o valoare maximă de 98% în primele 10 epoci, este esențial ca modelul să și-si ajusteze în continuare ponderile interne. Această metrică de acuratețe este de tip binar, evaluată independent pentru fiecare dintre cei 4 neuroni. Pentru exemplificare: un pacient în stadiul Proliferative cu etichetă adevărată [1,1,1,1] clasificat eronat în etapa Severe cu etichetă [1,1,1,0] va obține o acuratețe binară de 75% (3 din 4 neuroni corecți), deși diagnosticul final este eronat. Astfel, valorile mari de acuratețe raportate nu reflectă performanța reală a modelului. Eficiența antrenării este confirmată și în figura 4.36, unde funcția de eroare scade progresiv. Aceasta indică o convergență eficientă și justifică necesitatea dezghețării progresive ale ponderilor din rețea.




Figura 4.37. Matricea de confuzie în cazul regresiei ordinale

Analizând matricea de confuzie din figura 4.37, numărul de pacienți fals-negativi specifici claselor Mild și Moderate a scăzut semnificativ. Rețeaua a detectat mult mai eficient pacienții bolnavi, însă costul este reprezentat de ineficiența rețelei de a detecta pacienții sănătoși. Acest fapt se remarcă și în tabelul 4.5. Reamintirea pentru clas Mild a crescut semnificativ, atingând un scor de 0.411, ceea ce arată că din totalul pacienților ce prezintă o formă incipientă a afecțiunii, au fost detectați aproximativ 41%. Cu toate acestea, scorul F1 nu s-a îmbunătățit considerabil pentru nicio clasă, iar în schimb reamintirea pentru clasa No DR a scăzut considerabil. Din punct de vedere al evaluării conform metricii QWK, se remarcă performanțe similare (0.685 în etapa precedentă, 0.678 pentru experimentul curent). Întrucât numărul pacienților sănătoși corect detectați a scăzut considerabil, se poate observa o scădere și în cazul acurateții globale, ce atinge 66.9%. Utilizând regresia ordinală, vom obține mai puțini pacienți fals-negativi, însă numărul alarmelor false va crește considerabil, un model de acest fel punând o presiune suplimentară asupra medicilor.

Adițional, în cadrul funcției de cost, am inițializat adițional parametrul $\alpha=0.75$, fapt ce va acorda o atenție și mai sporită pentru cele 4 clase ale pacienților ce prezintă retinopatie diabetică.

Global Metrics	QWK: 0.6780	Acc: 0.669		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.909	0.728	0.809	39.533
Mild	0.130	0.411	0.197	3.762
Moderate	0.554	0.559	0.556	7.861
Severe	0.406	0.440	0.422	1.214
Proliferative	0.768	0.458	0.574	1.206

Tabelul 4.5. Valori ale metricilor de precizie, reamintire, scor F1, acuratețe globală, QWK, pentru experimentul 10




Figura 4.38. Matricea de confuzie pentru regresie ordinală, parametrul $\alpha=0.75$

Figura 4.38 indică faptul că modelul reușește să minimizeze și mai mult numărul de pacienți fals-negativi atunci când se taxează mai drastic neclasificarea corespunzătoare a pacienților bolnavi. Cu toate acestea, numărul de pacienți fals-pozitivi crește exagerat de mult pentru această situație. Cu toate că penalizarea pacienților fals-pozitivi va fi mai efektivă din punct de vedere medical, numărul de suspecți va crește substanțial. Metrica QWK de 0.436 indică o concordanță moderată (scădere de la 0.678), ceea ce indică că modelul nu este optim pentru utilizare clinică.

Experiment 11: EfficientNet-B3 însoțit de algoritmi Shades-of-Gray+CLAHE de pre-procesare

O altă tehnică de pre-procesare des utilizată în aplicații bazate pe detecția afecțiunilor medicale este Shades-of-Gray. Pentru acest experiment, am pre-procesat imaginile utilizând acest algoritm. Am păstrat aceleași metode de augmentări, cât și tehnici de regularizare. Am păstrat pentru ultimul strat de clasificare cei 5 neuroni aferenți fiecărei clase, pentru ultimul strat s-a utilizat funcția de activare Softmax pentru clasificare. Ca și funcție de eroare, am păstrat Focal Loss pentru care am inițializat parametrul $\gamma=2$, $\text{label_smoothing}=0.1$. Etapele de fine-tuning au fost realizate identic ca și în experimentele precedente. Graficul 4.39 ce indică evoluția metricii de acuratețe confirmă faptul că ponderile interne se ajustează pentru ca modelul să extragă suficientă informație. Acuratețea crește brusc în primele 3 faze, după care se va ajusta fin cu o rată de învățare mai redusă pentru a nu pierde informațiile generale deja învățate ale conturilor unei imagini.




Figura 4.39. Evoluția metricii de acuratețe, pentru pre-procesarea Shades-of-Gray




Figura 4.40. Matricea de confuzie pentru setul de test pre-procesat Shades-of-Gray

Global Metrics	QWK: 0.6660	Acc: 0.748		Total: 53.576
Clasa	Precision	Recall	F1-Score	Support
No DR	0.888	0.843	0.865	39.533
Mild	0.182	0.183	0.183	3.762
Moderate	0.485	0.620	0.544	7.861
Severe	0.427	0.421	0.424	1.214
Proliferative	0.643	0.538	0.586	1.206

Tabelul 4.6. Metrici de evaluare a modelului obținut în experimentul 11

Figura 4.40 și tabelul 4.6 confirmă performanțe asemănătoare modelului antrenat pentru setul ce a fost pre-procesat utilizând algoritmul CLAHE pentru componenta L. Se remarcă un scor QWK egal cu 0.67, iar metricile de precizie și reamintire indică valori ușor mai reduce comparativ cu situația în care a fost aplicat algoritmul CLAHE. Rețeaua clasifică corect majoritatea pacienților sănătoși. Pentru clasele Mild și Severe se remarcă rezultate mai slabe, susținute de un scor F1 redus. Pentru clasa Proliferative, se remarcă cel mai bun rezultat dintre cazurile afectate de retinopatie.

Concluzii și direcții viitoare de cercetare

Sumarizând totalitatea capitolelor relatate, se poate afirma faptul că utilizarea rețelelor neuronale convoluționale în aplicații medicale aduce numeroase beneficii, acest fapt fiind confirmat și pentru problema clasificării etapelor individuale ale retinopatiei diabetice. Graficele aferente etapei de antrenare prezentate în capitolul aferent rezultatelor a confirmat faptul că modelul reușește să extragă în mod eficient informații de bază dintr-o imagine de tip fund de retină, precum microanevrisme, forme ale vascularizațiilor nervoase, informații despre aspectul general al maculei. Pe baza acestor informații, s-a acordat verdictul corespunzător ce indică în ce categorie aferentă celor cinci clase (pacient sănătos, pacient cu retinopatie ușoară, moderată, severă, respectiv etapa proliferativă ce reprezintă ultimul stadiu al afecțiunii oculare) a retinopatiei diabetice s-a situat fiecare pacient aferent lotului de test.

Pentru a rezolva această problemă de clasificare, au fost evaluate și comparate mai multe arhitecturi neuronale distincte. Inițial modelul de bază evaluat a fost ResNet50, pentru care s-a utilizat algoritmul de pre-procesare Ben Graham, obținându-se un scor QWK de 0.63, fapt care indică un model ce se încadrează în categoria de concordanță substanțială din punct de vedere clinic.

Ulterior, s-a testat o arhitectură cascadată, pentru a separa problema de clasificare în două etape distincte: primul model efectua discriminarea între pacienții bolnavi și cei sănătoși, iar cel de-al doilea model a fost utilizat pentru a descoperi stadiul bolii, incluzând o cale de urgență pentru pacienții fals-pozitivi clasificați în etapa a doua în mod eronat. Pentru a maximiza rezultatele, am calibrat pragul de clasificare pentru prima rețea binară. Această abordare a înregistrat un scor QWK de 0.65, fapt ce indică o creștere marginală.

Cele mai bune rezultate au fost obținute pentru experimentele în care s-a utilizat arhitectura EfficientNet-B3, cuplat cu algoritmul CLAHE pentru a spori calitatea eșantioanelor din lotul de antrenare. Pentru acest model s-a înregistrat un scor QWK record de 0.6856.

Cu toate acestea, evaluarea unui sistem medical de screening nu se poate baza exclusiv pe metrice statistice globale. Modelul bazat pe regresie ordinală, deși înregistrează un QWK ușor inferior (0.678), reduce semnificativ numărul de pacienți bolnavi clasificați eronat ca sănătoși de la 4467 la 2884, o reducere de 35%. În contextul retinopatiei diabetice, unde fals-negativii pot duce la progresia bolii până la stadii ireversibile, această reducere este clinic semnificativă.

Realizarea proiectului a presupus parcurgerea unor etape de cercetare și experimentare. Contribuțiile individuale aduse la nivelul lucrării se pot rezuma astfel:

- Studiarea metodelor existente în literatura de specialitate: Pe baza soluțiilor teoretice existente, am adaptat metoda în funcție de caracteristicile lotului de date de test și al infrastructurii avute la dispoziție.
- Propunerea unei metode proprii, pe baza celor deja existente în literatură, am dezvoltat un pipeline personalizat pentru a aborda problema clasificării retinopatiei diabetice.
- Crearea propriului set de date: Am fuzionat două seturi de antrenare distincte extrase din platforma Kaggle: EyePacs și Aptos, pentru a oferi robustețe modelului.
- Gestionarea dezechilibrelor din lotul de antrenare: Am subeșantionat totalitatea datelor din setul de antrenare pentru a întreține etapa de antrenare stabilă și pentru a evita fenomenul de supraantrenare.

- Crearea unui pipeline complex de pre-procesare a datelor: Acest flux s-a bazat pe decuparea regiunii de interes, urmat de aplicarea a diverși algoritmi consacrați în literatură (CLAHE, Ben Graham, Shades-of-Gray), totodată am aplicat măști specifice pentru curățarea fundalului.
- Evaluarea a trei configurări arhitecturale diferite: Am testat o rețea neuronală bazată pe conexiuni reziduale (ResNet50), o arhitectură bazată pe un sistem de triaj (compus din 2 arhitecturi ResNet50 cascade), cât și o arhitectură bazată pe scalări multiple (EfficientNet-B3)
- Optimizarea etapelor de antrenare prin utilizarea tehnicilor de regularizare: Am aplicat augmentări asupra lotului de antrenare, tehnici de Dropout, de normalizare a datelor la nivel de lot, înlocuirea etichetelor „dure” cu etichete „moi”, utilizarea metodei EarlyStopping pentru a preveni debutul supraînvățării caracteristicilor specifice lotului de antrenare.
- Optimizarea antrenării prin Fine-Tuning progresiv: Am dezghețat progresiv de la ieșire către intrarea rețelei blocurile convoluționale interne, utilizând diverse rate de învățare variabile utilizând funcțiile ReduceLROnPlateu, respectiv Cosine Warmup Scheduler, pentru a asigura o convergență stabilă a modelului.
- Testarea și evaluarea modelelor: Testarea modelelor pe setul public de test EyePacs, utilizând metrici de evaluare relevante pentru domeniul medical, precum matricea de confuzie, precizie reamintire și scor F1 pentru fiecare clasă, cât și Quadratic Weight Kappa.

În cadrul direcțiilor viitoare de cercetare, pe termen scurt aş încerca să efectuez operația de ensemble între mai multe modele obținute, practică des folosită atât în literatura de specialitate, cât și în competițiile derulate pe platforma de competiții Kaggle, pentru a optimiza metricile de măsură. Aş încerca implementarea unei arhitecturi de tip cascadă care să aibă la bază 2 rețele de tip EfficientNet-B3. Se va continua studierea articolelor de specialitate pentru a descoperi noi tehnici de pre-procesare ale imaginilor pentru a maximiza informațiile ce pot fi extrase de către rețelele convoluționale.

Pe termen lung, aş utiliza tehnici de augmentare bazate pe antrenarea unor rețele generativ adversariale ce pot genera noi eşantioane pentru lotul de antrenare. Astfel, problema dezechilibrului setului de date poate fi tratat, iar pe baza mai multor imagini, modelul va avea o capacitate de clasificare net superioară. Având un set mai larg de date, aş utiliza arhitecturi bazate pe mecanisme de atenție, datorită faptului că nu mai e necesară etichetarea manuală a tuturor datelor.

Bibliografie

- [1] T. Y. Wong, C. M. G. Cheung, M. Larsen, S. Sharma and R. Simó, “Diabetic retinopathy,” *Nature Reviews Disease Primers*, p. Art. no. 16012, March 2016.
- [2] S. Tuteja, “Fundoscopic Appearances of Retinal Pathologies,” [Online]. Available: [\[https://geekymedics.com/fundoscopy-appearances-of-retinal-pathologies/\]](https://geekymedics.com/fundoscopy-appearances-of-retinal-pathologies/)(<https://geekymedics.com/fundoscopy-appearances-of-retinal-pathologies/>). [Accessed 26 Octombrie 2025].
- [3] S. R. Rath, “Diabetic Retinopathy 224x224 (2019 Data),” 2019. [Online]. Available: [\[https://www.kaggle.com/datasets/sovit Rath/diabetic-retinopathy-224x224-2019-data\]](https://www.kaggle.com/datasets/sovit Rath/diabetic-retinopathy-224x224-2019-data)(<https://www.kaggle.com/datasets/sovit Rath/diabetic-retinopathy-224x224-2019-data>). [Accessed 26 Octombrie 2025].
- [4] M. Z. Atwany, A. H. Sahyoun and M. Yaqub, “Deep Learning Techniques for Diabetic Retinopathy Classification: A Survey,” *IEEE Access*, vol. 10, pp. 28642-28655, 2022.
- [5] A. A. Elngar, M. Arafa, A. Fathy, B. Moustafa, O. M. a. M. Shaban and N. Fawzy, “Image Classification Based On CNN: A Survey,” *Journal of Cybersecurity and Information Management (JCIM)*, vol. 6, no. 1, pp. 18-50, 2021.
- [6] J. Gui, T. Chen, J. Zhang, Q. Cao, Z. Sun, H. Luo and D. Tao, “A Survey on Self-Supervised Learning: Algorithms, Applications, and Future Trends,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 12, pp. 9052-9071, 2024.
- [7] JGraph Ltd., “diagrams.net,” 2026. [Online]. Available: <https://www.diagrams.net/>. [Accessed 3 Iunie 2026].
- [8] A. J. Kadhim, H. Seyedarabi, R. Afrouzian and F. S. Hasan, “Diabetic Retinopathy Classification Using Hybrid Color-Based CLAHE and Blood Vessel in Deep Convolution Neural Network,” *IEEE Access*, vol. 12, pp. 194750-194761, 2024.
- [9] B. Graham, “Kaggle Diabetic Retinopathy Detection competition report,” University of Warwick, Coventry, 2015.
- [10] G. D. Finlayson and E. Trezzi, “Shades of Gray and Colour Constancy,” in *Color and Imaging Conference*, 2004.
- [11] C. Shorten and T. M. Khoshgoftaar, “A survey on Image Data Augmentation for Deep Learning,” *Journal of Big Data*, vol. 6, no. 60, 2019.
- [12] D. D. T. Hendrycks, “Benchmarking Neural Network Robustness to Common Corruptions and Perturbations,” in *International Conference on Learning Representations*, 2019.
- [13] D. Yin, R. G. Lopes, J. Shlens, E. D. Cubuk and J. Gilmer, “A Fourier Perspective on Model Robustness in Computer Vision,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.

- [14] A. Rădoi, *Inteligență Artificială 2: Recunoașterea Formelor - Curs 7: Rețele Convoluționale*, București: Universitatea Națională de Știință și Tehnologie Politehnica București, 2025.
- [15] J. Liang, "Image classification based on RESNET," *Journal of Physics: Conference Series*, vol. 1634, no. 1, p. 012110, 2020.
- [16] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, Nevada, USA, 2016.
- [17] J. Liao, L. Guo, L. Jiang, C. Yu, W. Liang, K. Li and F. Pop, "A machine learning-based feature extraction method for image classification using ResNet architecture," *Digital Signal Processing*, vol. 160, p. 105036, 2025.
- [18] R. H. Finjan, A. S. Rasheed, A. A. Hashim and M. Murtdha, "Arabic handwritten digits recognition based on convolutional neural networks with resnet-34 model," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 21, no. 1, pp. 174-178, 2021.
- [19] L. Wen, W. Li and L. Gao, "A transfer convolutional neural network for fault diagnosis based on ResNet-50," *Neural Computing and Applications*, vol. 32, pp. 6111-6124, 2020.
- [20] M. B. Hossain, S. H. S. Iqbal, M. M. Islam, M. N. Akhtar and I. H. Sarker, "Transfer learning with fine-tuned deep CNN ResNet50 model for classifying COVID-19 from chest X-ray images," *Informatics in Medicine Unlocked*, vol. 30, p. 100916, 2022.
- [21] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- [22] A. Batool and Y.-C. Byun, "Lightweight EfficientNetB3 Model Based on Depthwise Separable Convolutions for Enhancing Classification of Leukemia White Blood Cell Images," *IEEE Access*, 2023.
- [23] R. Ochoa-Ornelas, A. Gudiño-Ochoa, J. A. García-Rodríguez and S. Uribe-Toscano, "A robust transfer learning approach with histopathological images for lung and colon cancer detection using EfficientNetB3," *Healthcare Analytics*, vol. 7, 2025.
- [24] J. Hu, L. Shen and G. Sun, "Squeeze-and-Excitation Networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [25] IBM, "What is Fine-Tuning?," 2026. [Online]. Available: <https://www.ibm.com/think/topics/fine-tuning>. [Accessed 5 Iulie 2026].
- [26] M. C. I. Kandel, "The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset," *ICT Express*, vol. 6, pp. 312-315, 2020.
- [27] S. Afaq and S. Rao, "Significance Of Epochs On Training A Neural Network," *INTERNATIONAL JOURNAL OF SCIENTIFIC & TECHNOLOGY RESEARCH*, vol. 9, pp. 485-488, 2020.

- [28] M. Lin, Q. Chen and S. Yan, "Network in Network," *arXiv preprint arXiv:1312.4400*, 2014.
- [29] A. Labach, H. Salehinejad and S. Valaee, "Survey of Dropout Methods for Deep Neural Networks," *arXiv preprint arXiv:1904.13310*, 2019.
- [30] L. Prechelt, "Early Stopping - but when?," in *Neural Networks: Tricks of the trade*, Springer, Berlin, Heidelberg, 1998, pp. 55-69.
- [31] S. Ioffe and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," in *Proceedings of the 32nd International Conference on Machine Learning*, 2015.
- [32] T.-Y. Lin, P. Goyal, R. Girshick, K. He and P. Dollár, "Focal Loss for Dense Object Detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [33] R. Müller, S. Kornblith and G. E. Hinton, "When Does Label Smoothing Help?," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [34] Z. Liu, "Super Convergence Cosine Annealing with Warm-Up Learning Rate," in *International Conference on Artificial Intelligence, Big Data and Algorithms (CAIBDA)*, 2022.
- [35] O. Caelen, "A Bayesian interpretation of the confusion matrix," *Annals of Mathematics and Artificial Intelligence*, vol. 81, pp. 429-450, 2017.
- [36] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427-437, 2009.
- [37] D. J. D. Vaughn, "On The Direct Maximization of Quadratic Weighted Kappa," *arXiv*, 2015.
- [38] J. R. Landis and G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, no. 1, pp. 159-174, 1977.
- [39] R. R. e. a. Selvaraju, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," in *IEEE International Conference on Computer Vision (ICCV)*, Venice, 2017.
- [40] Kaggle, "Diabetic Retinopathy Detection," 2015. [Online]. Available: <https://www.kaggle.com/competitions/diabetic-retinopathy-detection/data>. [Accessed 26 Februarie 2026].
- [41] Cahoon, M. Shaban, A. Switala, A. Mahmoud and A. El-Baz, "Diabetic Retinopathy Screening Using A Two-Stage Deep Convolutional Neural Network Trained on An Extremely Un-Balanced Dataset," in *SoutheastCon 2022*, 2022.

Anexă Cod

Codul sursă pentru experimentul 10 – Regresie Ordinală

```
#Bibliotecile utilizate
import os
import math
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import tensorflow as tf
import cv2
import albumentations as A
from tqdm import tqdm

from tensorflow.keras.applications
import EfficientNetB3

from
tensorflow.keras.applications.efficie
ntnet import preprocess_input

from tensorflow.keras.models import
Model

from tensorflow.keras.layers import
Dense, GlobalAveragePooling2D,
Dropout, BatchNormalization

from
tensorflow.keras.preprocessing.image
import ImageDataGenerator

from tensorflow.keras.optimizers
import Adam

from tensorflow.keras.callbacks
import LearningRateScheduler,
EarlyStopping, ModelCheckpoint

from sklearn.model_selection import
GroupShuffleSplit

from sklearn.metrics import
classification_report,
confusion_matrix, cohen_kappa_score

from IPython.display import display
import tensorflow.keras.backend as K

print("Clasificare Ordinală")

IMG_SIZE = (512, 512) #Dimensiunea
imaginilor

BATCH_SIZE = 16      #Dimensiunea
lotului

CLASS_NAMES = ['No DR', 'Mild',
'Moderate', 'Severe',
'Proliferative']

# Calea către CSV-urile originale
BASE_DIR_CSV =
'/kaggle/input/datasets/suppermass/da
taset-licenta/DATASET_FINAL'

CALE_TRAIN_CSV =
os.path.join(BASE_DIR_CSV,
"train.csv")

CALE_TEST_CSV =
os.path.join(BASE_DIR_CSV,
"test.csv")

# Căile către folderele cu imaginile
pre-procesate
PROCESSED_TRAIN_RGB =
'/kaggle/input/notebooks/suppermass/p
re-procesare-
imaginefnet/processed_train_rgb'

PROCESSED_TEST_RGB =
'/kaggle/input/notebooks/suppermass/p
re-procesare-
imaginefnet/processed_test_rgb'

#Citirea si balansarea esantioanelor
de train

print("\nÎncărcare date din CSV...")
df_raw = pd.read_csv(CALE_TRAIN_CSV)
if 'id_code' in df_raw.columns:
df_raw =
```

```

df_raw.rename(columns={'id_code':
'id', 'diagnosis': 'label'})

df_raw['id'] =
df_raw['id'].apply(lambda x: str(x)
if str(x).lower().endswith(('.jpg',
'.png')) else f"{x}.png")

df_raw['label'] =
df_raw['label'].astype(int)

#balansarea datelor
sampled_dfs = []
for c in range(5):

    df_c = df_raw[df_raw['label'] ==
c]

    if c in [0, 2]:

        n_samples = min(5000,
len(df_c)) #Daca exista minim 5000 de
esantioane in lotul de train pt o
clasa, acestea vor fi integral
utilizate

sampled_dfs.append(df_c.sample(n=n_sa
mples, random_state=42))

    else:

        sampled_dfs.append(df_c) #
Altfel incarcam toate esantioanele
existente

df_balanced =
pd.concat(sampled_dfs).sample(frac=1,
random_state=42).reset_index(drop=True)

df_test = pd.read_csv(CALE_TEST_CSV)
if 'id_code' in df_test.columns:
df_test =
df_test.rename(columns={'id_code':
'id', 'diagnosis': 'label'})

df_test['id'] =
df_test['id'].apply(lambda x: str(x)
if str(x).lower().endswith(('.jpg',
'.png')) else f"{x}.png")

df_test['label'] =
df_test['label'].astype(int)

```

```

# Modificarea etichetelor pentru
descompunere binara

for i in range(1, 5):

    df_balanced[f'q{i}'] =
(df_balanced['label'] >=
i).astype(np.float32)

    df_test[f'q{i}'] =
(df_test['label'] >=
i).astype(np.float32)

coloane_target = ['q1', 'q2', 'q3',
'q4']

# Split train-validare-testare

def extrage_id_pacient(nume_fisier):
return
str(nume_fisier).split('.')[0].split(
'_')[0]

df_balanced['patient_id'] =
df_balanced['id'].apply(extrage_id_pa
cient)

gss = GroupShuffleSplit(n_splits=1,
test_size=0.2, random_state=42)

train_idx, val_idx =
next(gss.split(df_balanced,
df_balanced['label'],
groups=df_balanced['patient_id']))

train_df =
df_balanced.iloc[train_idx].copy()

val_df =
df_balanced.iloc[val_idx].copy()

print(f"\n Date finale pentru
antrenare: Train={len(train_df)} |
Val={len(val_df)} |
Test={len(df_test)}")

# 6. Generare si aplicare augmentari
asupra setului de train

augmentari_train = A.Compose([

    A.HorizontalFlip(p=0.5),
    A.VerticalFlip(p=0.5),

```

```

        A.Rotate(limit=360,
border_mode=cv2.BORDER_CONSTANT,
fill=0, p=1.0),

        A.RandomScale(scale_limit=0.1,
p=0.3), A.Resize(512, 512),

A.CoarseDropout(num_holes_range=(1,
2), hole_height_range=(0.1, 0.2),
hole_width_range=(0.1, 0.2), fill=0,
p=0.5),

        A.GaussNoise(std_range=(0.1,
0.3), p=0.3),

A.RandomBrightnessContrast(brightness
_limit=0.1, contrast_limit=0.1,
p=0.3),

        A.ElasticTransform(alpha=30,
sigma=5,
border_mode=cv2.BORDER_CONSTANT,
fill=0, p=0.2),
1)

def wrapper_train(img):

    return
preprocess_input(augmentari_train(ima
ge=img.astype(np.uint8))['image'].ast
ype(np.float32))

def wrapper_test(img):

    return
preprocess_input(img.astype(np.float3
2))

datagen_train =
ImageDataGenerator(preprocessing_func
tion=wrapper_train)

datagen_val_test =
ImageDataGenerator(preprocessing_func
tion=wrapper_test)

gen_train =
datagen_train.flow_from_dataframe(

    train_df, PROCESSED_TRAIN_RGB,
x_col="id", y_col=coloane_target,

```

```

        target_size=IMG_SIZE,
batch_size=BATCH_SIZE,
class_mode="raw", shuffle=True)

gen_val =
datagen_val_test.flow_from_dataframe(

    val_df, PROCESSED_TRAIN_RGB,
x_col="id", y_col=coloane_target,

    target_size=IMG_SIZE,
batch_size=BATCH_SIZE,
class_mode="raw", shuffle=False)

gen_test =
datagen_val_test.flow_from_dataframe(

    df_test, PROCESSED_TEST_RGB,
x_col="id", y_col=None,

    target_size=IMG_SIZE,
batch_size=BATCH_SIZE,
class_mode=None, shuffle=False)

# Construire model

base_model =
EfficientNetB3(weights='imagenet',
include_top=False,
input_shape=(*IMG_SIZE, 3))

for layer in base_model.layers:
layer.trainable = False

x =
GlobalAveragePooling2D()(base_model.o
utput) # Blocul Global Average
Pooling

x =
BatchNormalization(name='batch_norm_t
op')(x) # Blocul Batch Normalization

x = Dropout(0.3)(x) #Blocul Dropout

outputs = Dense(4,
activation='sigmoid',
name='clasificator_ordinal')(x)
#Clasificare, activare sigmoid

model =
Model(inputs=base_model.input,
outputs=outputs)

```

```

def
focal_loss_ordinal_echilibrat(gamma=2
.0): #Functie de loss

    def focal_loss_fn(y_true,
y_pred):

        y_pred =
tf.clip_by_value(y_pred, K.epsilon(),
1.0 - K.epsilon())

        bce = -y_true *
tf.math.log(y_pred) - (1.0 - y_true)
* tf.math.log(1.0 - y_pred)

        p_t = y_true * y_pred + (1.0
- y_true) * (1.0 - y_pred)

        focal_factor =
tf.math.pow(1.0 - p_t, gamma)

        loss = focal_factor * bce

        return
tf.reduce_mean(tf.reduce_sum(loss,
axis=-1))

    return focal_loss_fn

# Antrenare model

fazele_antrenarii = [

    {"nume": "Faza_1_Cap", "desc":
"Cap Ordinal", "keywords": [], "lr":
1e-3, "epoci": 10}, # Dezghetare cap
ordinal timp de 10 epoci

    {"nume": "Faza_2_Top", "desc": "+
Block 7", "keywords": ['block7'],
"lr": 5e-5, "epoci": 10}, #
Dezghetare bloc 7 timp de 10 epoci

    {"nume": "Faza_3_Mid", "desc": "+
Block 6", "keywords": ['block7',
'block6'], "lr": 2e-5, "epoci": 10},
# Dezghetare bloc 6 timp de 10 epoci

    {"nume": "Faza_4_Deep", "desc":
"+ Block 4 & 5", "keywords":
['block7', 'block6', 'block5',
'block4'], "lr": 1e-5, "epoci": 10},
#Dezghetare bloc 4 si 5 timp de 10
epoci

    {"nume": "Faza_5_Tot", "desc": "+
Block 2 & 3", "keywords": ['block7',
'block6', 'block5', 'block4',
'block3', 'block2'], "lr": 5e-6,
"epoci": 10}# Dezghetare bloc 2 si 3
timp de 10 epoci

```

```

]

def
get_cosine_warmup_scheduler(lr_max,
total_epochs, warmup_epochs=2,
lr_min=1e-6): # Functia de cosine
warmup, lr minim definit va fi pana
la 1e-6, iar dupa 2 epoci va atinge
valoarea maxima

    def scheduler(epoch, lr):

        if epoch < warmup_epochs:
return (lr_max / warmup_epochs) *
(epoch + 1)

        progress = (epoch -
warmup_epochs) / max(1, (total_epochs
- warmup_epochs))

        return float(lr_min + 0.5 *
(lr_max - lr_min) * (1 +
math.cos(math.pi * progress))) #
Formula ce indica cum va varia rata
de invatare

    return scheduler

istoric_total = {'accuracy': [],
'val_accuracy': [], 'loss': [],
'val_loss': []}

rezultate_qwk = []

for i, faza in
enumerate(fazele_antrenarii, 1):

    print(f"\n{'='*70}")

    print(f" FAZA {i}: {faza['desc']}
| LR Max: {faza['lr']}")

    print(f"{'='*70}")

    for layer in model.layers:

        este_in_faza = any(kw in
layer.name for kw in
faza['keywords'])

        if este_in_faza and not
isinstance(layer,
BatchNormalization): layer.trainable
= True

```

```

        elif
layer.name.startswith('clasificator_o
rdinal') or
layer.name.startswith('batch_norm_top
'): layer.trainable = True

        else: layer.trainable = False

model.compile(optimizer=Adam(learning
_rate=faza['lr']),

loss=focal_loss_ordinal_echilibrat(ga
mma=2.0),

metrics=['accuracy'])

callbacks = [

LearningRateScheduler(get_cosine_warm
up_scheduler(lr_max=faza['lr'],
total_epochs=faza['epoci'],
warmup_epochs=3)),

EarlyStopping(monitor='val_loss',
patience=6, min_delta=0.001,
restore_best_weights=True,
verbose=1),

ModelCheckpoint(filepath=f"ordinal_be
st_{faza['nume']}.keras",
monitor='val_loss',
save_best_only=True, mode='min',
verbose=0)

]

gen_train.reset();
gen_val.reset()

history = model.fit(gen_train,
validation_data=gen_val,
epochs=faza['epoci'],
callbacks=callbacks, verbose=1)

for key in istoric_total:
istoric_total[key].extend(history.his
tory[key])

```

```

# Voi rula inferenta dupa fiecare
dezghetare succesiva pe lotul de test

gen_test.reset()

print(f" Se rulează inferența pe
setul de TEST...")

y_pred_probabilitati =
model.predict(gen_test, verbose=1)

#Inferență ordinală strictă

y_pred =
np.zeros(len(y_pred_probabilitati),
dtype=int)

for j in
range(len(y_pred_probabilitati)):

    stadiu = 0

    for prob in
y_pred_probabilitati[j]:

        if prob >= 0.5:

            stadiu += 1

        else:

            break

    y_pred[j] = stadiu

y_true = df_test['label'].values

#Calcul QWK si restul de
statistici

qwk = cohen_kappa_score(y_true,
y_pred, weights='quadratic')

rezultate_qwk.append({'Faza':
faza['nume'], 'QWK': qwk})

print(f"\n QWK DUPĂ
{faza['desc']}: {qwk:.4f}")

raport =
classification_report(y_true, y_pred,
target_names=CLASS_NAMES,
output_dict=True)

```

```

df_raport =
pd.DataFrame(raport).transpose().round(3)

display(df_raport)

df_raport.to_csv(f"ordinal_raport_test_{faza['nume']}.csv")

cm = confusion_matrix(y_true,
y_pred)

plt.figure(figsize=(7, 6))

sns.heatmap(cm, annot=True,
fmt='d', cmap='Blues',
xticklabels=CLASS_NAMES,
yticklabels=CLASS_NAMES)

plt.title(f'Matrice Confuzie TEST
({faza["desc"]}) | QWK: {qwk:.3f}',
fontweight='bold')

plt.ylabel('Reale');
plt.xlabel('Predicții')

plt.savefig(f"ordinal_matrice_test_{faza['nume']}.png", dpi=300,
bbox_inches='tight')

plt.show()

# Salvari finale si grafice

df_ist = pd.DataFrame(istoric_total)
df_ist.index += 1

fig, (ax1, ax2) = plt.subplots(1, 2,
figsize=(16, 5))

ax1.plot(df_ist.index,
df_ist['accuracy'], label='Train
Acc')

ax1.plot(df_ist.index,
df_ist['val_accuracy'], label='Val
Acc', ls='--')

ax1.set_title('Evoluție Acuratețe
Ordinală'); ax1.legend()

ax2.plot(df_ist.index,
df_ist['loss'], label='Train Loss
(BCE)', color='red')

ax2.plot(df_ist.index,
df_ist['val_loss'], label='Val Loss
(BCE)', color='green', ls='--')

ax2.set_title('Evoluție Loss
Ordinal'); ax2.legend()

plt.savefig("ordinal_grafic_evolutie_
complet.png", dpi=300,
bbox_inches='tight')

plt.show()

model.save("ordinal_model_final_Etapa
3_2.keras") #Se salveaza modelul

df_ist.to_csv("ordinal_istoric_antren
are_complet.csv") #Rezultate
antrenare

pd.DataFrame(rezultate_qwk).to_csv("o
rdinal_scoruri_qwk_faze.csv",
index=False)

df_predictii_finale = pd.DataFrame({
'id': df_test['id'],
'y_true': y_true,
'y_pred_class': y_pred
})

df_predictii_finale.to_csv("ordinal_p
redictii_brute_test_final.csv",
index=False) #Salvare predictii

```

Pre-procesarea CLAHE

```
def aplica_auto_crop_patrat(img):
    gray = cv2.cvtColor(img,
cv2.COLOR_RGB2GRAY)
    _, thresh = cv2.threshold(gray,
10, 255, cv2.THRESH_BINARY)
    contours, _ =
cv2.findContours(thresh,
cv2.RETR_EXTERNAL,
cv2.CHAIN_APPROX_SIMPLE)

    if contours:
        c = max(contours,
key=cv2.contourArea)
        x, y, w, h =
cv2.boundingRect(c)

        # Plasă de siguranță anti-
crash: aplicăm logica ta de tăiere
doar dacă imaginea nu e o scamă/beznă
        if w > 20 and h > 20:
            center_x, center_y = x +
w // 2, y + h // 2
            side_length = max(w, h)
            half_side = side_length
// 2
            x_new, y_new = max(0,
center_x - half_side), max(0,
center_y - half_side)
            x_end, y_end =
min(img.shape[1], center_x +
half_side), min(img.shape[0],
center_y + half_side)

            img_crop =
img[y_new:y_end, x_new:x_end]

            # Încă un check de
siguranță pentru a returna matricea
curată

            if img_crop.size > 0:
                return img_crop
    return img

def aplica_clahe_lab(img):
    lab = cv2.cvtColor(img,
cv2.COLOR_RGB2LAB)
    l, a, b = cv2.split(lab)
    clahe =
cv2.createCLAHE(clipLimit=2.0,
tileGridSize=(8, 8))
    cl = clahe.apply(l)
    lab_eq = cv2.merge((cl, a, b))
    return cv2.cvtColor(lab_eq,
cv2.COLOR_LAB2RGB)

def aplica_masca_circulara(img,
target_size):
    img_resized = cv2.resize(img,
target_size)
    mask = np.zeros(target_size[:2],
dtype=np.uint8)
    cv2.circle(mask,
(target_size[0]//2,
target_size[1]//2),
target_size[0]//2, 255, -1)
    return
cv2.bitwise_and(img_resized,
img_resized, mask=mask)
```

Pre-procesarea Ben Graham

```
def aplica_auto_crop_patrat(img):
    gray = cv2.cvtColor(img,
cv2.COLOR_RGB2GRAY)
    _, thresh = cv2.threshold(gray,
10, 255, cv2.THRESH_BINARY)
    contours, _ =
cv2.findContours(thresh,
cv2.RETR_EXTERNAL,
cv2.CHAIN_APPROX_SIMPLE)
    if contours:
        c = max(contours,
key=cv2.contourArea)
        x, y, w, h =
cv2.boundingRect(c)
        center_x, center_y = x + w //
2, y + h // 2
        side_length = max(w, h)
        half_side = side_length // 2
        x_new, y_new = max(0,
center_x - half_side), max(0,
center_y - half_side)
        x_end, y_end =
min(img.shape[1], center_x +
half_side), min(img.shape[0],
center_y + half_side)
        return img[y_new:y_end,
x_new:x_end]
    return img

def aplica_ben_graham_verde_x3(img):
    #Extrage canalul Verde, aplică
normalizarea Ben Graham și îl duplică
x3
    #canalul verde este indexul 1
    g = img[:, :, 1]
    # Sigma pentru blur este
proporțional cu dimensiunea imaginii
    sigmaX = img.shape[1] / 30.0
    blur = cv2.GaussianBlur(g, (0,
0), sigmaX=sigmaX)
    # Formula: G * 4 - Blur * 4 + 128
    g_bg = cv2.addWeighted(g, 4,
blur, -4, 128)
    # Duplicăm canalul procesat de 3
ori
    return cv2.merge([g_bg, g_bg,
g_bg])
def aplica_masca_circulara(img,
target_size):
    #Se aplică pentru a curăța
marginile gri adăugate de Ben Graham.
    img_resized = cv2.resize(img,
target_size)
    mask = np.zeros(target_size[:2],
dtype=np.uint8)
    cv2.circle(mask,
(target_size[0]//2,
target_size[1]//2),
target_size[0]//2, 255, -1)
    return
cv2.bitwise_and(img_resized,
img_resized, mask=mask)
```

Pre-procesarea Shades-of-Gray

```
def shade_of_gray_cc(img, power=6):
    # Estimează iluminantul pe baza
    # normei Minkowski și normalizează
    # culorile

    img = img.astype('float32')
    img_power = np.power(img, power)
    rgb_vec = np.power(np.mean(img_power,
                                axis=(0, 1)), 1 / power)

    rgb_vec = rgb_vec /
    np.sqrt(np.sum(np.power(rgb_vec,
                              2.0)))

    rgb_vec = 1.0 / (rgb_vec *
                     np.sqrt(3))
    img = img * rgb_vec.reshape((1, 1,
                                   3))

    return np.clip(img, 0,
                    255).astype('uint8')

def
preprocesare_completa_sog(img_bgr,
                           target_size=(512, 512)):
# Pipeline complet: BGR→RGB → resize
→ Shade-of-Gray → CLAHE → mască

img_rgb = cv2.cvtColor(img_bgr,
                        cv2.COLOR_BGR2RGB)

img_resized = cv2.resize(img_rgb,
                          target_size,
                          interpolation=cv2.INTER_LANCZOS4)

img_sog =
shade_of_gray_cc(img_resized,
power=6) # normalizare culoare

img_clahe = aplica_clahe_lab(img_sog)
# contrast local

img_final =
aplica_masca_circulara(img_clahe,
target_size) # eliminare fundal

return img_final
```

Arhitectura Cascadată din cadrul Experimentului 7

```
def inferenta_cascada(gate_model,
                      severity_model, img_paths,
                      gate_threshold=0.5, batch_size=32):
    n = len(img_paths)
    gate_proba = np.zeros(n)
    clase_finale = np.zeros(n, dtype=int)

    # — PAS 1: Gate Model – clasificare
    # binară sănătos/bolnav —
    for start in range(0, n, batch_size):
        end = min(start + batch_size, n)
        batch = []

        for path in img_paths[start:end]:
            img = cv2.imread(path)
            img = cv2.cvtColor(img,
                                cv2.COLOR_BGR2RGB)

            img = cv2.resize(img, IMG_SIZE)

            img =
preprocess_input(img.astype(np.float32))

            batch.append(img)

            preds =
gate_model.predict(np.array(batch),
verbose=0).flatten()

            gate_proba[start:end] = preds

            gate_bolnav = gate_proba >=
gate_threshold

            clase_finale[~gate_bolnav] = 0 #
sănătoșii rămân direct la clasa 0

            idx_bolnavi =
np.where(gate_bolnav)[0]

# — PAS 2: Severity Model –
clasificare grad boală (doar bolnavi)
—
```

```

        for start in range(0,
            len(idx_bolnavi), batch_size):
            end = min(start + batch_size,
                len(idx_bolnavi))
            batch_idx = idx_bolnavi[start:end]

            batch = []

            for i in batch_idx:
                img = cv2.imread(img_paths[i])

                img = cv2.cvtColor(img,
                    cv2.COLOR_BGR2RGB)

                img = cv2.resize(img, IMG_SIZE)

                img =
preprocess_input(img.astype(np.float3
                2))

                batch.append(img)

                preds =
severity_model.predict(np.array(batch
                ), verbose=0)

            for j, idx in enumerate(batch_idx):
                clase_finale[idx] =
                    np.argmax(preds[j])

            return clase_finale, gate_proba

# — Baleiere praguri Gate pentru
    optimizarea compromisului
        precizie/recall —

thresholds = [0.25, 0.30, 0.35, 0.40,
    0.45, 0.50]

    for thresh in thresholds:
        y_pred, gate_p = inferenta_cascada(
            gate_model, severity_model,
            img_paths, gate_threshold=thresh)

        qwk = cohen_kappa_score(y_true,
            y_pred, weights='quadratic')

        print(f"Threshold={thresh} |
            QWK={qwk:.4f}")

```